

國立臺灣大學工學院工業工程學研究所

碩士論文

Institute of Industrial Engineering

College of Engineering

National Taiwan University

Master Thesis



基於短期風速預測進行整合風力電場分散式發電與電
動汽車作為儲能設備的虛擬電廠收益分析

Profit Analysis of Virtual Power Plant Integrated with
Wind Farms as Distributed Generation and Electric
Vehicles as Energy Storage Device Based on Short-Term
Wind Speed Prediction

彭新翔

Hsin-Hsiang Peng

指導教授: 吳文方 博士

Advisor: Wen-Fang Wu Ph.D.

中華民國 109 年 5 月

May, 2020

國立臺灣大學碩士學位論文

口試委員會審定書



基於短期風速預測進行整合風力電場分散式發電
與電動汽車作為儲能設備的虛擬電廠收益分析

Profit Analysis of Virtual Power Plant Integrated
with Wind Farms as Distributed Generation and
Electric Vehicles as Energy Storage Device Based on
Short-Term Wind Speed Prediction

本論文係彭新翔君（R05546030）在國立臺灣大學工業工程學研究所完成之碩士學位論文，於民國 109 年 5 月 1 日承下列考試委員審查通過及口試及格，特此證明

口試委員：_____

（指導教授）

_____	_____
_____	_____
_____	_____
_____	_____

所 長：_____





致謝

感谢





摘要

持續成長的電力需求以及民眾環保意識抬頭，加上傳統集中式電力系統的缺點日漸浮現，各國紛紛開始關注能夠充分利用再生能源且具有良好環境效益的分散式發電（Distributed Generation, DG）技術。

本研究以虛擬電廠（Virtual Power Plant, VPP）概念整合分散式能源的風力電場與作為儲能裝置的電動汽車，考慮時間電價進行調度規劃來參與電力市場交易，並透過模型預測控制（Model Predictive Control, MPC）在有限時域下針對動態變化的虛擬電廠進行發電與儲能規劃來獲得最佳收益；其中，為鼓勵電動汽車整合於虛擬電廠中參與電力市場交易，本研究中提出以額外充電作為紅利取代直接給予金錢的鼓勵方式；此外，本研究提出了基於小波轉換對時間序列進行訊號分解，並結合傳統時間序列預測與支持向量迴歸預測的小波分解 ARIMA-SVR 組合預測模型，用以根據歷史風速資料預測風力電場發電。

並於案例模擬中使用我國東吉島測站 2018 年間的歷史風速資料為基礎，進行短期風力預測與收益模型分析後，驗證了此最佳化收益方案的可行性。分析結果亦顯示，短期風速預測中採用小波分解 ARIMA-SVR 組合預測模型相較傳統單一預測模型在預測能力上有小幅度提升，而使用了電動汽車作為儲能裝置的虛擬電廠能夠獲取更高的收益。

關鍵字：虛擬電廠、風力發電、電動汽車、時間序列預測、ARIMA 模型、支持

向量迴歸、模型預測控制、短期風速預測





Abstract

With the increasing demand for electricity and the rising of public awareness of environmental protection, as well as the increasingly emerging disadvantages of traditional centralized power system, more and more attention has been paid to distributed generation (DG) by each county, which can make full use of renewable energy and has good environmental benefits.

In this study, the concept of Virtual Power Plant (VPP) was applied to integrate with wind farms as distributed generation and electric vehicles as energy storage devices, participating in electricity market transactions by considering Time of Use Price (TOU) for scheduling. Model Predictive Control (MPC) was used to maximize benefits from power generation and storage planning for dynamic changed virtual power plants in finite time domain. Of which, in order to integrate electric vehicles into virtual power plants and participate in electricity market transactions, the compensation payment mode of providing free charging instead of direct giving of money was adopted in this study. Furthermore, the signal decomposition of time series based on wavelet transform was proposed in this study, and the traditional time series prediction and wavelet decomposition ARIMA-SVR combination prediction model for support vector regression prediction were combined to predict wind farm power generation based on historical wind speed data.


Based on the historical wind speed data of DONGJIDAO in 2018 in the case simulation, the feasibility of this profit optimization model was verified after applying the short-term wind power forecast and profit model. The analysis results also showed that compared with the traditional single prediction model, there is a small increase by adopting ARIMA-SVR combined prediction model with wavelet decomposition in the short-term wind power forecast. While the virtual power plant using electric vehicles as energy storage devices could obtain higher profits.

Keywords: Virtual Power Plant, Wind Power, Electric Vehicle, Time Series Prediction, ARIMA Model, Support Vector Regression, Model Predictive Control, Short-Term Wind Speed Prediction




目錄

	Page
口試委員審定書	i
致謝	iii
摘要	v
Abstract	vii
目錄	ix
圖目錄	xiii
表目錄	xv
符號列表	xvii
第一章 緒論	1
1.1 前言	1
1.2 研究背景	3
1.2.1 電力系統發展	3
1.2.2 再生能源發展	6
1.2.3 電動汽車發展	7
1.2.4 我國能源政策	8
1.3 研究動機	10
1.4 本文架構	11



第二章	文獻回顧	15
2.1	虛擬電廠概念	15
2.2	虛擬電廠應用	16
2.3	風電預測評估	17
2.4	電動汽車電池	19
2.5	小結	19
第三章	研究方法	21
3.1	研究流程概述	21
3.2	風力發電預測	21
3.2.1	小波時頻分析	22
3.2.2	時間序列模型	26
3.2.3	支持向量迴歸	34
3.2.4	模型評價方法	39
3.3	收益模型分析	39
3.3.1	自由電力市場	39
3.3.2	風機功率模型	43
3.3.3	電動汽車電池	44
3.3.4	模型預測控制	46
3.4	小結	50
第四章	模型建構	51
4.1	風力電場發電預測	51
4.1.1	時間序列預測建模流程	51
4.1.2	支持向量迴歸建模流程	51



4.1.3	組合預測模型建模流程	53
4.2	虛擬電廠收益分析	55
4.2.1	虛擬電廠結構概述	55
4.2.2	風力電場等效模型	56
4.2.3	電動汽車等效模型	57
4.2.4	電力市場收益模型	58
4.2.5	預測控制求解流程	62
4.3	小結	63
第五章 案例分析		65
5.1	模擬情境概述	65
5.2	風速預測分析	66
5.2.1	歷史風速概述	66
5.2.2	單一預測模型	67
5.2.3	組合預測模型	71
5.2.4	模型誤差比較	75
5.3	收益結果分析	76
5.3.1	電動汽車有無影響	76
5.3.2	電動汽車數量需求	76
5.4	小結	76
第六章 結論與建議		77
6.1	結論	77
6.2	建議	78


參考文獻

附錄 A — 再生能源場址

附錄 B — 風力機組規格

B.1 Enercon E40/600 Model 93

B.2 Enercon E44/900 Model 94






圖目錄

圖 1.1	臺灣地區年度用電量	2
圖 1.2	世界各地年度用電量	2
圖 1.3	臺灣電力公司供電系統	4
圖 1.4	全球風力發電與太陽能發電累積裝置容量	7
圖 1.5	論文架構	13
圖 2.1	虛擬電廠概念	16
圖 3.1	離散小波轉換階層架構	25
圖 3.2	二維平面上最優分類線	35
圖 3.3	常見電力市場架構	41
圖 3.4	模型預測控制基本原理	46
圖 4.1	時間序列預測建模流程	52
圖 4.2	支持向量迴歸建模流程	52
圖 4.3	一般等權組合預測模型建模流程	54
圖 4.4	小波分解組合預測模型建模流程	54
圖 4.5	整合風力電場與電動汽車的虛擬電廠模型	55
圖 4.6	模型預測控制求解流程	62
圖 5.1	原始風速時間序列	67
圖 5.2	差分風速時間序列	68
圖 5.3	差分時間序列自相關係數函數 (ACF) 圖	69
圖 5.4	差分時間序列偏自相關係數函數 (PACF) 圖	69
圖 5.5	單一 ARIMA 模型短期風速預測結果	70
圖 5.6	單一 SVR 模型短期風速預測結果	71

圖 5.7	一般等權 ARIMA-SVR 組合模型短期風速預測結果	72
圖 5.8	原始風速時間序列進行小波分解的近似分量 A_2	74
圖 5.9	原始風速時間序列進行小波分解的細節分量 D_2	74
圖 5.10	原始風速時間序列進行小波分解的細節分量 D_1	74
圖 5.11	小波分解 ARIMA-SVR 組合模型短期風速預測結果	75
圖 B.1	Enercon E40/600 Model 風機功率曲線	94
圖 B.2	Enercon E44/900 Model 風機功率曲線	95





表目錄

表 1.1	常見分散式發電技術主要污染物排放量	6
表 1.2	臺灣地區再生能源裝置容量與發電數量	10
表 3.1	常見小波母函數特徵	24
表 3.2	整合自迴歸移動平均模型的特例	32
表 3.3	自相關函數與偏相關函數之特徵	33
表 3.4	滿足 Mercer 條件的常見核函數	38
表 3.5	常見二次電池的特性比較	45
表 5.1	臺灣電力公司非夏季兩段式電價	66
表 5.2	原始風速時間序列 ADF 檢定結果	67
表 5.3	差分風速時間序列 ADF 檢定結果	68
表 5.4	差分風速時間序列 $ARIMA(p, d, q)$ 適配檢驗	70
表 5.5	原始風速時間序列進行小波分解的重構誤差	72
表 5.6	原始風速時間序列 $D2$ 細節分量 ADF 檢定結果	73
表 5.7	原始風速時間序列 $D1$ 細節分量 ADF 檢定結果	73
表 5.8	風速預測模型評估結果	75
表 A.1	臺灣風力發電場址資料	88
表 A.2	臺灣太陽光電場址資料	90





符號列表

VPP	虛擬電廠 (Virtual Power Plant)
EM	電力市場 (Electric Market)
WF	風力電場 (Wind Farm)
EV	電動汽車 (Electric Vehicle)
$p_e(t)$	時刻 t 的電力價格





第一章 緒論

本章為緒論，將簡述國內外電力需求狀況與傳統發電之困境，並分別從電力系統發展、再生能源發展、電動汽車發展與我國能源政策面相切入研究背景，最後說明本研究預期達到的目標以及章節組成架構。

1.1 前言

能源是人類社會維持生存與文明發展所不可或缺的基礎，但隨著經濟發展與科技進步所延伸出的能源危機、空氣汙染與溫室效應，儼然已是世界各國不得不面對的緊迫難題。

長期以來，國內外的電力需求持續成長，圖 1.1 的臺灣地區年度用電數量 [1] 顯示自 1999 年至 2018 年間，臺灣地區的年度用電數量由 1,609 億度 (160.9 TWh) 成長至 2,665 億度 (266.5 TWh)；於此同時，圖 1.2 的世界各國年度用電數量 [2] 亦顯示世界各國的年度用電量由 126,120 億度 (12612 TWh) 成長至 229,640 億度 (22964 TWh)，其中又以我國在內的亞洲地區成長最為顯著。考量未來產業變遷、電動汽車普及…等新增用電需求，我國經濟部推估至 2025 年間，臺灣地區用電數量每年將成長約 1.86%，年度用電量將達到 3,029 億度 (302.9 TWh) [3]。




圖 1.1: 臺灣地區年度用電數量 [1]





圖 1.2: 世界各地年度用電數量 [2]



目前世界各國的電力來源主要以火力發電與核能發電為主，根據統計，在 2018 年時，火力發電與核能發電約佔臺灣地區總發電數量的 94.19% [1]，火力發電與核能發電約佔全球總發電數量的 74% [4]。其中火力發電需要大量開發燃煤、石油與天然氣…等不可再生能源，同時也導致相關產業的溫室氣體排放量居高不下；而核能發電有著較高的發電效率，並且幾乎沒有空氣汙染問題，但隱含安全隱憂，比如 1986 年發生於俄羅斯的車諾比事件（Chernobyl disaster）、1979 年發生於美國的三哩島事件（Three Mile Island accident）與 2011 年發生於日本的福島第一核電廠事故（Fukushima Daiichi nuclear disaster）。

在民眾環保意識抬頭與核能發電安全隱憂的時空背景下，世界各國開始重新審視既有的能源產業與政策。於此同時，能夠充分利用再生能源，具有良好的環境效益的分散式發電（Distributed Generation, DG）技術近年來受到越來越多的關注，但礙於起初設計輸配電網路時並未納入考慮，為解決此問題，整合分散式能源（Distributed Energy Resources, DERs）、可控式負載與儲能設備（Battery Energy Storage, BESS）為一個整體，使其參與電力系統運行與電力市場交易的虛擬電廠（Virtual Power Plant, VPP）概念也應運而生。

1.2 研究背景

1.2.1 電力系統發展

電力系統是指由發電系統、輸電系統與配電系統所組成的複雜系統，負責處理電力供給中所依序會經歷的發電、輸電、配電與用電四個過程 [5]。目前包含臺灣本島、澎湖、金門與馬祖在內的中華民國地區電力供應，由隸屬於我國經濟部的國營事業機構——臺灣電力股份有限公司（簡稱台電）負責。如圖 1.3 所示，台

電公司供電系統中核能、水力與火力發電廠產生電力後，需透過變壓器將電壓升至 345 仟伏特 (345 kV)，再利用輸電線路輸送電力，最後透過高壓變電所與一次變電所分別降壓至 161 仟伏特 (161 kV)、69 仟伏特 (69 kV) 後，提供給科學園區、工業園區及大眾運輸工具…等大型用戶用電，並透過配電變電所、二次變電所及配電系統再進行降壓，提供一般用戶做為民生用電使用。[6]

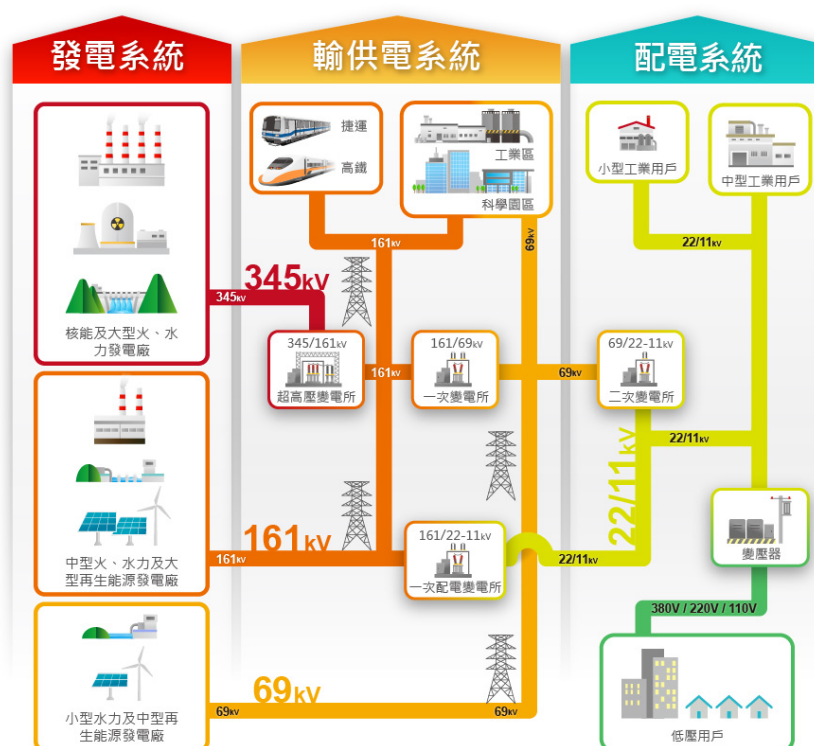


圖 1.3: 臺灣電力公司供電系統

目前世界各國的電力系統仍以傳統集中式大型電網系統為主，雖然長期以來具有很好的規模經濟效益，然而隨著經濟與科技發展，人們對於能源供給穩定性的要求日益提高，傳統集中式大型電網系統的缺陷也逐漸浮現。傳統集中式大型電網系統所面臨的問題，大致上可以歸納為以下幾點：

- **發電機組集中建設，長距傳輸能量折損：**考量建設成本，發電機組與用電用戶所在地通常距離遙遠，容易導致電力生產與分配不均，需要跨區輸電來解決電力不足問題，長距離的電力傳輸過程所累積的能量損失亦十分可觀。以

臺灣地區為例，輸電系統分為北、中、南三個地區，過去資料顯示在用電尖峰季節，北部地區電力仍需中南部地區補足，過去十年間臺灣地區電力的線路損失率約為 4%。^[1]



- **局部故障影響整體，可靠穩定備受考驗：**傳統電網中，超過負載的高壓電纜將使得過載電流必須由附近的其他輸配電纜負責分攤，大量的電流回流可能導致輸配電纜超出負載而燒斷，故障擴散進而導致大面積的停電效應。比如 2003 年美加大停電（影響人數達 5,000 萬人）、2006 歐洲大停電（影響人數達 1,200 萬人）和 2012 年印度大停電（影響人數達 62,000 百萬人）…等大規模停電事件。
- **發電倚賴化石燃料，背離能源永續目標：**燃煤、石油與天然氣…等火力發電燃料屬於不可再生能源，生產電力過程中也伴隨著溫室氣體的排放，核能發電亦隱含安全隱憂。國際間越趨重視相關環境保護與資源永續問題，傳統集中式大型電網的主要發電方式勢必需要進行改善。

相對於傳統集中式大型電網系統，能夠充分利用再生能源的分散式發電（Distributed Generation, DG）技術近年來備受關注，國內外許多文獻對於分散式發電並沒有規範的定義，一般是指分散地布置於用電用戶周圍，容量較小的發電裝置^[7]。由於短時間內無法完全取代傳統集中式大型電網系統，目前的分散式電源多以接入既有電網運行為主，為了儘量減少併入分散式電源所引起的網路耗損與可靠性降低，世界各國均致力於發展智慧電網（smart grid）與微型電網（microgrid）技術。前者結合電力系統與資訊系統，利用資訊與通訊技術進行電力設備的自動化與最佳化；後者整合多個分散式電源組成拓譜結構，並可以自由切換連接模式或孤島模式，提升電力系統可靠度。



1.2.2 再生能源發展

為了抑制持續嚴峻的全球暖化現象，聯合國於 1997 年簽署「京都議定書」規範工業國家未來溫室氣體排放目標，因此各國逐漸將能源產業開發重心轉移至核能發電與再生能源發電。

表 1.1 為常見分散式發電技術的主要污染物排放量 [8]，顯示再生能源普遍具有潔淨低環境汙染的特性，其中又以風力發電與太陽能發電在發電過程中不會排放汙染物表現最佳。除此之外，近年來更有研究表示風力發電與太陽能發電能夠緩解地下水水位下降，進一步降低供水壓力與糧食危機。[9]

表 1.1: 常見分散式發電技術主要污染物排放量 [8]

發電技術	CO ₂	NO _x	SO ₂	CO	PM-10
內燃機組	444.52 ~ 498.95	0.14 ~ 2.72	可忽略	0.91 ~ 4.08	0 ~ 0.27
燃料電池	362.87 ~ 635.03	< 0.02	0	0.01 ~ 0.05	可忽略
生物質能	0 ~ 1043.26	0.14 ~ 2.72	< 0.14	0.91 ~ 4.08	0.27 ~ 1.81
風力發電	0	0	0	0	0
太陽能發電	0	0	0	0	0

kg/MW · h

根據歷年統計資料，全球的風力發電累計裝置容量從 2000 年僅 18,039 千瓩 (18,039 MW)，成長至 2018 年的 591,091 千瓩 (591,091 MW)；全球的太陽能發電累計裝置容量則自 2000 年僅 1,288 千瓩 (1,288 MW)，成長至 2018 年的 509,300 千瓩 (509,300 MW)。圖 1.4 為 1980 年至 2019 年的全球風力發電與太陽能發電累積裝置容量 [10, 11]，顯示近年來不論是風力發電亦或是太陽能發電皆發展迅速。

受到招標、競標及綠色憑證等市場機制、世界各國政策政策支持與建置成本逐漸降低…等因素影響，風力發電與太陽能發電等再生能源發展前景十分強




圖 1.4: 全球風力發電與太陽能發電累積裝置容量 [10, 11]

勁，全球風能協會（Global Wind Energy Council, GWEC）預估到 2024 年風力發電將再有約 300,000 千瓩（300,000 MW）的新增裝置容量 [12]，國際能源署（International Energy Agency, IEA）則預估到 2024 年時，太陽能發電的新增裝置容量將成長至 600,000 千瓩（600,000 MW） [13]。

1.2.3 電動汽車發展

隨著再生能源的發展，輸配電網對環境越趨友善的同時，也帶動了電動車產業的革新以及電力需求的成長。電動汽車（Electric Vehicle, EV）一般按照驅動原理劃分為以下幾類：

1. 燃料電池汽車（Fuel Cell Vehicle, FCV）：使用氫作為燃料產生電能帶動馬達運作，但大眾對於氫燃料的安全性存在疑慮，車款已逐漸被淘汰。
2. 電池電動汽車（Battery Electric Vehicle, BEV）：配置大型容量電池，馬達運作僅透過電池提供能源供給，其中電量由外部電源進行補充。
3. 油電混合汽車（Hybrid Electric Vehicle, BHEV）：同時使用汽油與電池作為驅動能量來源，透過電動機輔助降低車輛整體油耗量。

4. 插電混合汽車 (Plug-in Hybrid Electric Vehicle, PHEV)：相較於油電混合汽車而言，可以透過插座進行充電，電力充足時可以純電模式行駛降低碳排放，電力不足轉為燃油行駛，減少長程顧慮。

5. 增程電動汽車 (Extended-Range Electric Vehicle, EREV)：為解決長程行駛問題，在 BEV 的基礎上，加裝增程器通過燃油發電對電池進行充電。

傳統依賴內燃機帶來動力的交通工具在離開生產線後，每公里的溫室氣體排放量就已固定下來，而電動汽車的溫室氣體排放量能夠隨著能量來源越趨潔淨逐年降低。聯合國國際資源委員會 (International Resource Panel) 的研究表示在燃煤佔比超過七成的國家推動電動汽車發展，會導致空氣汙染增加 [14]；但近年來各國積極推動再生能源發展，根據彭博新能源財經 (BloombergNEF, BNEF) 的研究顯示，在 2018 年電動汽車比起燃油汽車低約 40% 的二氧化碳排放量 [15]。

我國為減少空氣汙染，行政院於 2017 年通過的《空氣汙染防制行動方案》中將分三階段推動全台電動車化，目標於 2040 年達到新售汽機車全面自動化。近年來在政府補貼政策激勵下，電動汽機車逐漸受到民眾認可與青睞，電動汽機車佔新增汽機車掛牌數量逐年上升。

1.2.4 我國能源政策

臺灣再生能源發展的濫觴，始於我國政府為因應「京都議定書」規範的溫室氣體減量標準，於 1998 年所召開的第一次全國能源會議，提出以減碳為主要目標，鼓勵發展再生能源技術。至 2008 年時通過《永續能源政策綱領》與《再生能源發展條例》，期望藉由政策規劃改變能源架構，將有限資源作有效的使用，兼顧能源安全、經濟發展與環境保護，以滿足未來世代發展的需要。我國行政院 2012 年將智慧電網列入「國家節能減碳總計畫」中，推動智慧電網並實際推展至澎湖

縣東吉島、屏東縣林邊鄉…等處進行實域驗證；並於 2015 年通過《溫室氣體減量及管理法》，目標在 2050 年將溫室氣體排放量降低至 2005 年的 50% 以下。



為落實臺灣環境永續，我國經濟部於 2012 年針對風力發電與太陽能發電推動相關計畫，以「陽光屋頂百萬座、千架海陸風力機」為口號，規劃於 2030 年達成兩項願景：

- **陽光屋頂百萬座**：採「逐步擴大」與「先屋頂後地面」的原則，向民間推動太陽能發電設置，規劃於 2030 年推廣屋頂型太陽能發電系統設置容量達 6,200 千瓩 (6200 MW)。
- **千架海陸風力機**：採「先陸域後離岸」、「先示範後區塊」與「先淺海後深海」的原則，規劃於 2030 年安裝約 800 架離岸風機與 450 架陸域風機，合計超過千架風機且設置容量達 5,200 千瓩 (5200 MW)。

考量國際趨勢與民意聲浪，我國於 2016 年新政府上台後，擬定在 2025 年全面廢除核能發電，邁向「非核家園」。為了補足廢除核能發所出現的能源缺口，政府更加積極推動再生能源發展，立法院於 2019 年通過《再生能源發展條例》修正案，設立 2025 年達成再生能源發電數量佔總發電數量 20% 的目標。表 1.2 為「再生能源發展條例」通過後，我國再生能源裝置容量與發電數量之狀況 [1]，顯示我國再生能源發展步調雖穩健但緩慢，以此成長趨勢要在 2025 年達到再生能源發電數量佔比 20% 的目標，尚有好幾許哩路要走。

為加速臺灣產業轉型並落實上述目標，我國政府亦提出包含「綠能科技」產業在內的 5+2 產業創新計畫，積極推動「太陽光電兩年推動計畫」、「綠能屋頂全民參與」、「風力發電四年推動計畫」、「智慧電表示範建置」、「沙崙智慧綠能科學城」…等計畫，希望結合國內需求發展相關能源產業，引進國內外投資的同時

表 1.2: 臺灣地區再生能源裝置容量與發電數量 [1]

年度	裝置容量 (MW)	裝置容量佔比 (%)	發電數量 (GWh)	發電數量佔比 (%)
2019	7,795	13.9 %	15,360	5.6 %
2018	6,246	11.9 %	12,634	4.6 %
2017	5,259	10.7 %	12,390	4.6 %
2016	4,726	9.5 %	12,753	4.8 %
2015	4,330	8.9 %	10,501	4.1 %
2014	4,065	8.4 %	9,944	3.8 %
2013	3,816	7.8 %	10,864	4.3 %
2012	3,594	7.4 %	10,684	4.3 %
2011	3,399	7.0 %	8,995	3.6 %
2010	3,197	6.5 %	8,642	3.5 %
2009	3,030	6.3 %	7,808	3.4 %

增加國內需求與就業機會。除此之外，我國行政院於 2017 年完成《電業法》修正，開放再生能源自由交易，未來我國電力市場將採躉購制度與自由市場雙軌運作，落實電業自由化（electricity liberalization）以推動我國綠色產業發展。

1.3 研究動機

近年來我國政府力倡能源轉型，為補足未來核能電廠除役後的能源缺口，在不額外興建電廠的民意傾向下採用整合分散式發電技術（Distributed Generation, DG）、儲能設備（Battery Energy Storage System, BESS）與電動汽車（Battery Electric Vehicle, BEV）的虛擬電廠（Virtual Power Plant, VPP）是一個可行的解決辦法。

目前國內虛擬電廠相關研究多以太陽光電與傳統儲能設備為主，考慮我國目前風力發電與太陽光電的累計裝置容量差異不大，且風力發電在相近容量裝置下

比起太陽光電具有更高的發電效率，本研究採用虛擬電廠概念整合近年來成長趨勢顯著的電動汽車作為儲能設備，使再生能源得以透過能量儲存緩衝本身的隨機性與間歇性，以短期風速預測電量為基礎，建構其參與電力市場的收益分析模型並使用模型預測控制方法（Model Predictive Control, MPC）在有限時域內根據過去狀態進行即時性調度，評估將電動汽車作為儲能設備參與電力市場交易是否具有益處。

本論文的研究目的條列如下：

1. 透過歷史風速資料，採用單一 ARIMA 模型、單一 SVR 模型與小波分解 ARIMA-SVR 組合模型進行風速時間序列的短期風速預測，並比較不同預測模型的預測能力。
2. 基於短期預測風速，建立整合風力電場作為分散式能源與電動汽車作為儲能設備的虛擬電廠收益模型。
3. 透過案例情境模擬，評估虛擬電廠中納入電動汽車作為儲能設備與未納入電動汽車作為儲能設備的收益比較。

1.4 本文架構

本文共分六章，整體架構如圖 1.5 所示。各章節內容分述如下：第一章為緒論，針對論文研究背景、研究動機與研究目的進行說明；第二章為文獻回顧，介紹本文研究內容所涉及的領域，並將蒐集到的國內外相關文獻進行統整與探討；第三章為研究方法，簡述研究流程及方法原理，做為日後驗證結果有效性的基礎；第四章為模型建構，提出風力機組與電動汽車的等效模型，以及虛擬電廠收益最佳化模型。第五章為案例分析，以我國東吉島測站真實風速資料進行發電預測，

評估在虛擬電廠中整合電動汽車作為儲能設備的收益狀況。第六章為結論與建議，將本研所得到的結果進行總結，作後說明研究限制並對未來可行的研究方向提出建議。



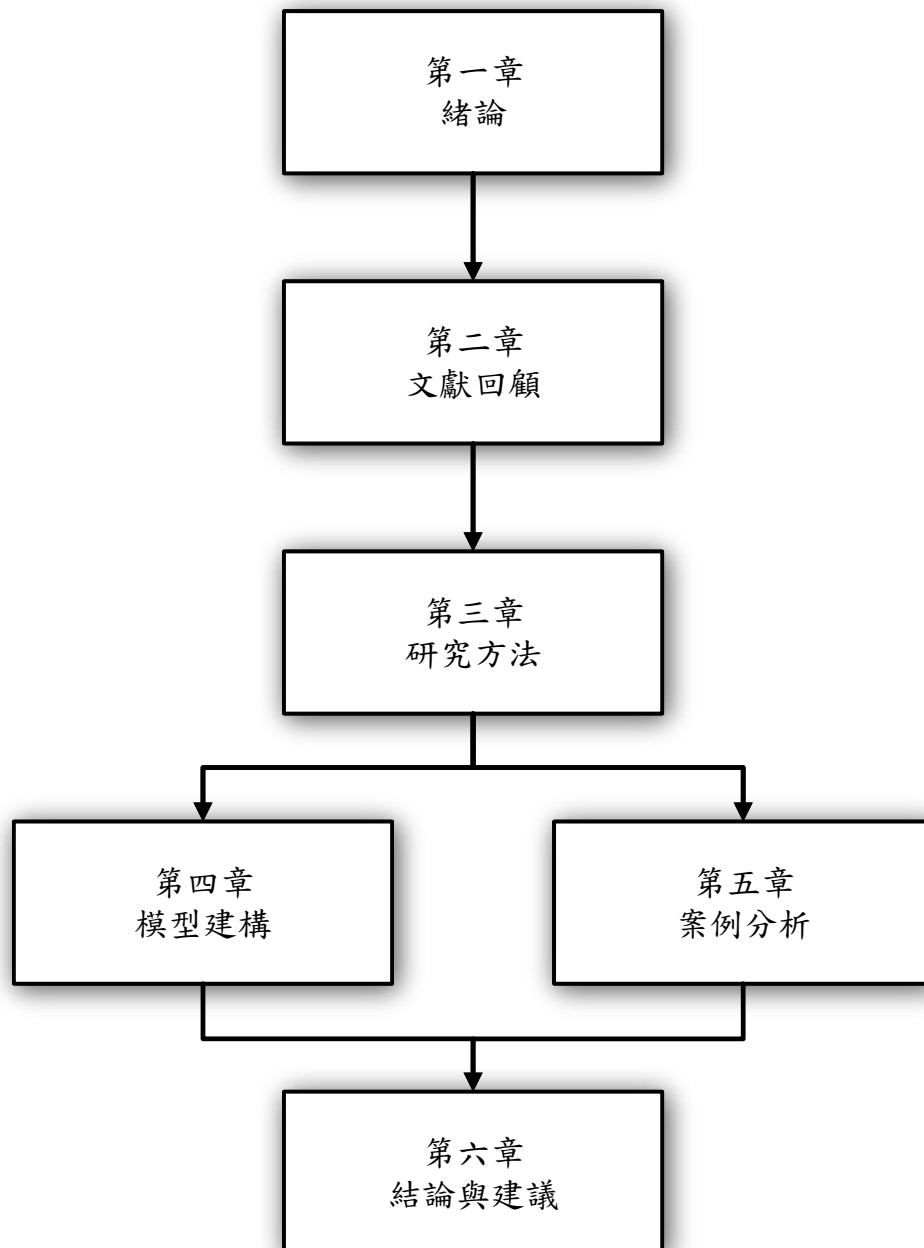


圖 1.5: 論文架構





第二章 文獻回顧

本章為文獻回顧，在對整合風力發電與電動汽車的虛擬電廠參與電力市場交易收益模型的建構與分析之前，需要對虛擬電廠、風力發電、電動汽車…等所涉及的領域進行文獻回顧。以下將研究過程中蒐集的文獻經整理後分為虛擬電廠概念、虛擬電廠應用、風電預測評估、電動汽車電池部分進行陳述。

2.1 虛擬電廠概念

由於再生能源的間歇性與隨機性會導致電力供給與需求兩側失衡，學者們提出了整合分散式能源 (Distributed Energy Resources, DERs)、儲能設備 (Battery Energy Storage System, BESS) 與電動汽車 (Battery Electric Vehicle, BEV) 的虛擬電廠 (Virtual Power Plant, VPP) 概念。

目前學術上並未對虛擬電廠有統一的定義 [16]：文獻 [17] 中指稱虛擬電廠為依賴於資訊系統，透過網路通訊技術遠端控制電力系統，實現自動輸配電、需量反應與能量儲存…等行為的整合網路；文獻 [18, 19] 將虛擬電廠分為技術與市場兩大部分，技術層面為提供電力來源的分散式發電，市場層面進行電力市場的交易與管理；文獻 [20] 將虛擬電廠定義分為控制與通訊兩大單位，前者以直接集中控制方式整合分散式能源，後者透過資通訊系統整合主動用電用戶網路。

綜合上述文獻，虛擬電廠可以視為是一個具備調度發電設備、整合用戶需求的中央控制中心，其概念如圖 2.1 所示。其中發電設備可以包括火力發電和核能發電等傳統發電技術，也可以包括風力發電、太陽能發電等再生能源發電技術；透過資訊設備進行發電數量預測、電力價格預測、電力需求預測…等，進行需求反應管理需求面。

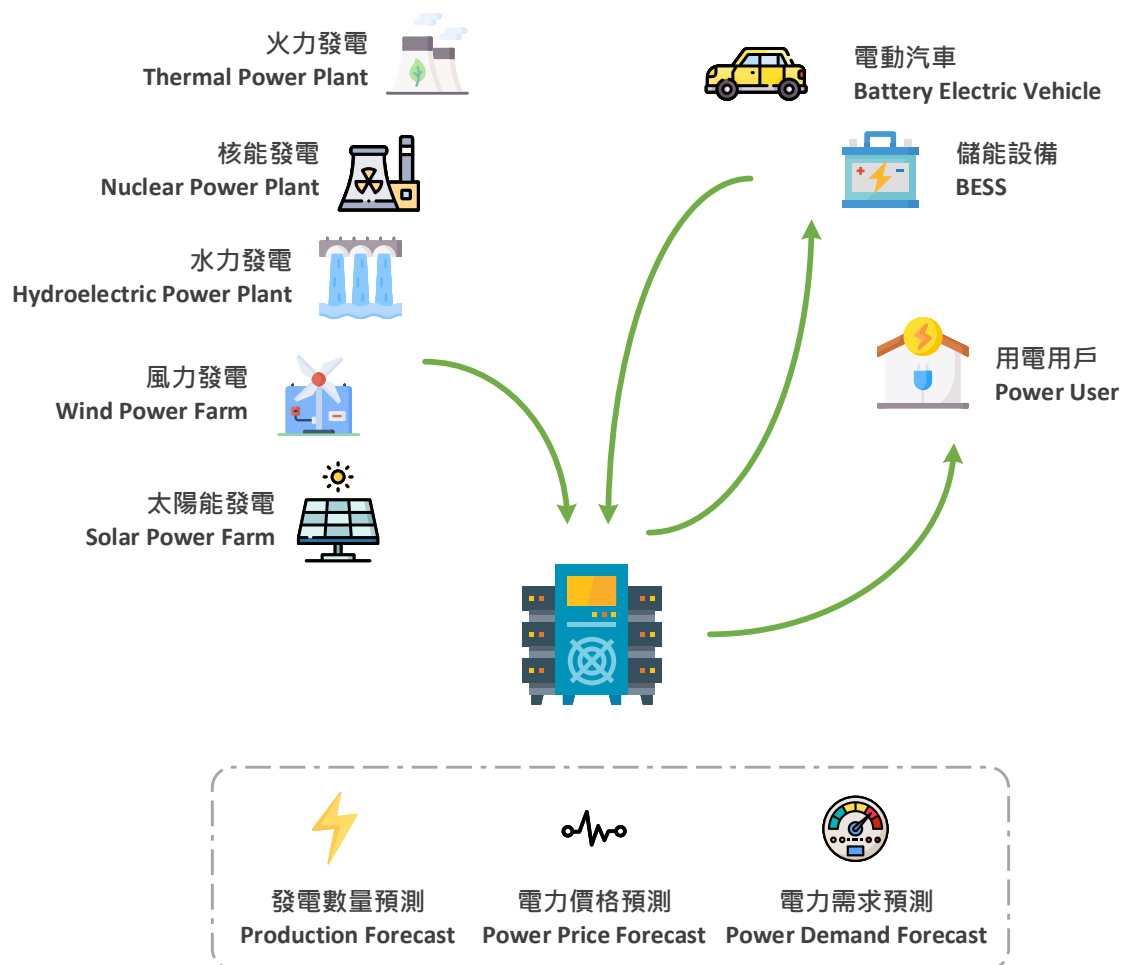



圖 2.1: 虛擬電廠概念

2.2 虛擬電廠應用

目前我國採用虛擬電廠概念進行應用與研究的相關文獻並不多，其中文獻 [21] 應用虛擬電廠之概念探討我國電力消費型態改變是否可以減少電力使用所造成的環境衝擊，採用了生命週期評估方法量化涵蓋人體毒性、水體優養化與全球



暖化…等在內的八類環境衝擊項目，發現應用虛擬電廠策略後造成的電力消費型態改變可以減少因電力消費所造成之環境衝擊；文獻 [22] 提出虛擬電廠在自由電力市場中的獲利模型並分析其獲利關鍵因素，利用 IEEE 37 母線測試饋線進行最佳電力潮流（Optimal Power Flow）模擬，發現變壓器供電上限和儲能電池設備為虛擬電廠營運商獲利的關鍵因素；文獻 [23] 應用虛擬電廠概念整合太陽光電與電池儲能設備，並採用時間電價與需量反應概念，探討不同用戶負載情境下虛擬電廠的調度狀況，發現儲能設備的調度與時間電價有關且用戶類型不會影響儲能設備調度結果。文獻 [24] 考慮表燈用戶、高壓用戶與整體社會參與虛擬電場運作時的經濟效益與機會成本，透過量化經濟效益模型評估不同用戶群體參與虛擬電廠是否具備經濟可行性，依據實證分析結果發現鼓勵電力用戶參與彈性電價方案有助於節省容量成本並具減碳效益，並提出政府應扶植虛擬電廠產業在我國發展、未來整體電力系統政策應具備跨系統配套方案…等政策論點。

2.3 風電預測評估

風力發電是目前再生能源發電中相對成熟的技術，如何對風速與風能進行預測與評估是風力發電項目可行性研究與輸配電網規劃研究的重要工作之一。依據歷年風速與風向資料進行的風力發電效益評估，根據時間尺度與應用層面的不同，可以分為長期風能評估（Wind Resource Assessment）與短期風能預測（Wind Energy Forecasting），長期風能評估用來評估一個地區是否有足夠潛力發展風力發電；而短期風能預測則用於電力系統中的調度規劃。


長期風能評估方面，多以一般統計方法將歷史風速資料與機率分布函數進行擬和，並透過風力機組的功率曲線轉換成對應的風能分布，用以評估潛在風能。目前已有許多學者投入相關研究，其中最早由文獻 [25] 提出透過不同的機率密度

函數描述風速，評估潛在風能的方法；文獻 [26, 27, 28] 採用機率分布函數擬合風速，分別評估加拿大和印度不同地區的潛在風能，作為風場選址考量；文獻 [29] 分別就臺灣地區過往四十年間的平時風速與極值風速探討其適用機率分布，發現韋伯機率函數可用於描述平時風速，與文獻 [30] 針對利比亞地區所進行的統計分析結果一致。

短期風能預測方面，目前多採時間序列方法觀察過去風速數據中隱含的趨勢，並針對風力電場進行風能預測，建立模型以預測未來風速。傳統時間序列預測的模型建構方法，根據平穩性條件可以分為應用於平穩時間序列的自迴歸模型（Auto Regressive Model, AR Model）、移動平均模型（Moving Average Model, MA Model）與自迴歸移動平均模型（Auto Regressive Moving Average Model, ARMA Model），以及應用於非平穩時間序列的差分自迴歸移動平均模型（Auto Regressive Integrated Moving Average Model, ARIMA Model）；近年來也有不少研究致力於將機器學習方法中的人工神經網路（Artificial Neural Network, ANN）與支持向量迴歸（Support Vector Regression, SVR）應用於時間序列預測。除此之外，為了更加準確地分析非平穩時間序列，通常會將時間序列進行分解，常見有以下分解方法：

- **趨勢分解 (Trend Decomposition)**：依據季節性將時間序列模型分解為週期分量（seasonal component）、趨勢分量（trend component）與殘留分量（remainder component），再與實際數據進行擬合求解模型參數，即 STL 分解（Seasonal-Trend Decomposition Based on Loess）。[31]
- **訊號分解 (Signal Decomposition)**：將時間序列透過訊號處理方式分解為高頻訊號與低頻訊號，分別進行模型擬合後將預測值進行疊合。常見訊號分解方法有傅立葉轉換（Fourier Transform, FT）、小波轉換（Wavelet

Transform, WT) 與經驗模態分解 (Empirical Mode Decomposition, EMD) ...等。[32]



相關研究中，文獻 [33] 提出 ARIMA-ANN 模型與 ARIMA-Kalman 模型來預測短期風速，比較後顯示兩者皆均具有良好的性能可以用於非固定風速預測；文獻 [34] 採用機器學習方法中的支持向量迴歸模型 (SVR Model)、多層感知器模型 (MLP Model) 與決策樹模型進行預測並比較其準確性，其中以支持向量迴歸模型的誤差最小；文獻 [35] 提出結合 EEMD 與 SVM 的組合模型進行風速預測，並以中國西北酒泉地區數據進行驗證，發現相較於傳統時間序列預測方法具有更高的準確性；文獻 [36] 基於小波轉換提出 Wavelet Packet-BFGS 模型、Wavelet Packet-ARIMA-BFGS 模型與 Wavelet-BFGS 模型進行短期風速預測，實驗案例表明三種混合模型都有不錯的表現；文獻 [37] 以梧棲地區 2013 年的觀測資料，採用 ARIMA 模型與 LSSVM 模型進行風速預測，發現僅使用風速時間序列作為預測的結果相較於納入其餘氣象資料的多屬性時間序列預測結果更為準確。

2.4 電動汽車電池

2.5 小結

目前，國內外都有優秀的學者在進行相關的研究。由文獻回顧可以得知，。因此，需要考量到。





第三章 研究方法

本章為研究方法，首先對本文的研究流程進行概述，並將研究流程劃分成數據資料蒐集、風力發電預測與收益模型分析…等步驟，這一章節主要將針對各步驟中所使用到的不同的原理與方法進行介紹與說明，其餘模型建構與實現的細節則留待後續章節中提到時再進行詳細敘述。

3.1 研究流程概述

本文研究流程大致上可以劃分成數據資料蒐集、風力發電預測與收益模型分析三個步驟。數據資料蒐集部分，收集我國再生能源發電廠址資料與對應地區鄰近的中央氣象局歷史風速，作為後續風力預測以及模擬算例的依據；風力發電預測部分，主要目的在推估風力發電於各時刻的發電量，提供收益最佳化模型進行求解；收益模型分析部分，根據預測所得的各時刻風力機組預測發電數量，進行有限移動時域下的模型預測控制規劃求解。

3.2 風力發電預測

風力發電預測部分將過去風速資料透過時間序列建構風速預測模型，用以推估未來某一時刻 t 的風速 $v(t)$ ，並根據風力機組模型轉換為對應的發電功率

$p_{wt}(t)$ 。其中使用的時間序列混合預測模型，是先透過小波轉換將時間序列進行分解，並分別將分解後的高頻與低頻訊號建立整合自迴歸移動平均模型與支持向量迴歸模型，最後再將預測結果進行重構。



3.2.1 小波時頻分析

短期風速預測的時間跨度較小，通常不考慮季節性影響，本研究中的時間序列分解將採用訊號處理中經常使用的小波轉換（Wavelet Transform, WT）作為處理工具，其概念與傅立葉轉換（Fourier Transform, FT）類似，目前被廣泛用於量子力學、醫學影像與機器診斷…等領域。

3.2.1.1 傅立葉轉換（Fourier Transform, FT）

標準的傅立葉轉換將訊號由時間頻域轉換至空間頻域，假設 $x(t)$ 是滿足可積分條件的時間訊號，使用 $e^{-i\omega t}$ 的弦波訊號進行組成，則其傅立葉轉換的積分表示式如方程式 (3.1) 所示。

$$\mathcal{FT}\{x\}(\omega) = \int_{-\infty}^{\infty} x(t)e^{-i\omega t} dt \quad (3.1)$$

由於捨棄了時間頻域的資訊，因此無法從上述傅立葉變換中得到該訊號於不同時間點的頻率資訊，例如訊號發出時間、訊號是否延遲、訊號延遲時間…等。針對傅立葉轉換無法傳達時間變化頻率的缺陷，學者 Gabor 在文獻 [38] 中提出添加窗函數（window function）的短時傅立葉轉換（Short-Time Fourier Transform, STFT）進行分析。使用 $\omega(t - \tau)$ 作為窗函數的短時傅立葉轉換積分式如方程式

(3.2) 所示。



$$STFT\{x\}(\omega, \tau) = \int_{-\infty}^{\infty} x(t) \omega(t - \tau) e^{-i\omega t} dt \quad (3.2)$$

採用不同寬度的窗函數會在時間頻域與空間頻域上有不同的解析度：較寬的窗函數有較高的空間頻域解析度，但時間頻域解析度較低；較窄的窗函數有較高的時間頻域解析度，但空間頻域解析度較低。小波轉換的積分表示式如方程式 (3.3) 所示，使用了一組具有震盪特性且能夠迅速衰減至零的小波母函數（Mother Wavelet）逼近目標函數，以解決短時傅立葉轉換中的窗函數由於大小和形狀固定，在應對不同頻率訊號時的侷限性。

$$WT\{x\}(a, b) = \int_{-\infty}^{\infty} x(t) \psi_{a,b}(t) dt \quad (3.3)$$

其中， $\psi_{a,b}(t)$ 是作為轉換基底的小波母函數。如方程式 (3.4) 所示，式中尺度參數 a 表示週期長度，平移參數 b 表示移動長度，分別代表空間軸上的縮放與時間軸上的平移，滿足 $a, b \in \mathbb{R}$ 且 $a \neq 0$ 。

$$\psi_{a,b}(t) = \frac{1}{\sqrt{|a|}} \psi\left(\frac{t-b}{a}\right) \quad (3.4)$$

為滿足小波分解在不同領域應用下的需求差異，學者提出了眾多的小波母函數如 Daubechies 小波、Symlet 小波與 Coiflet 小波…等。在選擇小波母函數時會考慮以下性質：

- 緊支撐 (Compactly Supported)：當尺度函數與小波函數只在有限區間內存在非零狀態，稱其具備緊支撐性，區間寬度越大的小波函數具備較好的局



部分辨與去除雜訊能力。

- **正交性 (Orthonormal)**：若小波係數之間的相關程度越小，分解後的訊號在重構後可以獲得較為平滑的效果。
- **對稱性 (Symmetric)**：影響小波基底在變換前後的偏題程度，採用具備對稱性的小波函數分解訊號，有利於訊號的恢復與重建。
- **消失矩 (Vanishing Moments)**：若 $\int \psi(t)t^m dt = 0$ 則稱該小波函數具有 m 階的消失矩，較高的消失矩具有較好的訊號壓縮與提取資訊能力。

常見的小波母函數型態與特性如表 3.1 所示。

表 3.1: 常見小波母函數特徵

小波母函數	緊支撐	支撐寬度	對稱性	正交性	消失矩
Sinc	否	無限	是	是	否
Harr	是	1	是	是	1
Meyer	否	無限	是	是	無限
Ricker	否	無限	是	否	1
Morlet	否	無限	是	否	
Symlet (symN)	是	$2N - 1$	近似對稱	是	N
Coiflet (cN)	是	$6N - 1$	近似對稱	是	$2N$
Daubechies (dbN)	是	$2N - 1$	是	是	N

3.2.1.2 連續小波轉換 (Continuous Wavelet Transform, CWT)

小波轉換中，小波母函數的取值範圍主要依賴於尺度參數和平移參數，若 a 和 b 在實數域中為連續，則連續小波轉換可以表示如方程式 (3.5) 所示。

$$CWT\{x\}(a, b) = \frac{1}{\sqrt{|a|}} \int_{-\infty}^{\infty} x(t) \bar{\psi} \left(\frac{t-b}{a} \right) dt \quad (3.5)$$

其中， $\bar{\psi}$ 為 ψ 的共軛複數。在實際情況中，小波轉換應存在其反轉換才有意義，因此必須滿足方程式 (3.6) 所表示的小波轉換容許性條件 (Admissible Condition)，式中的 C_ψ 稱為容許性常數 (Admissible Constant)，表示如方程式 (3.7) 所示。

$$0 < C_\psi < \infty \quad (3.6)$$

$$C_\psi = \int_{-\infty}^{\infty} \frac{|\hat{\psi}(\omega)|^2}{|\omega|} d\omega \quad (3.7)$$

3.2.1.3 離散小波轉換 (Discrete Wavelet Transform, DWT)

離散小波變換經常被用於數值分析與時頻分析中，但並沒有簡單而明確的方程式用以表達輸入與輸出之間的關係，通常以圖 3.1 所示的階層式架構表示。

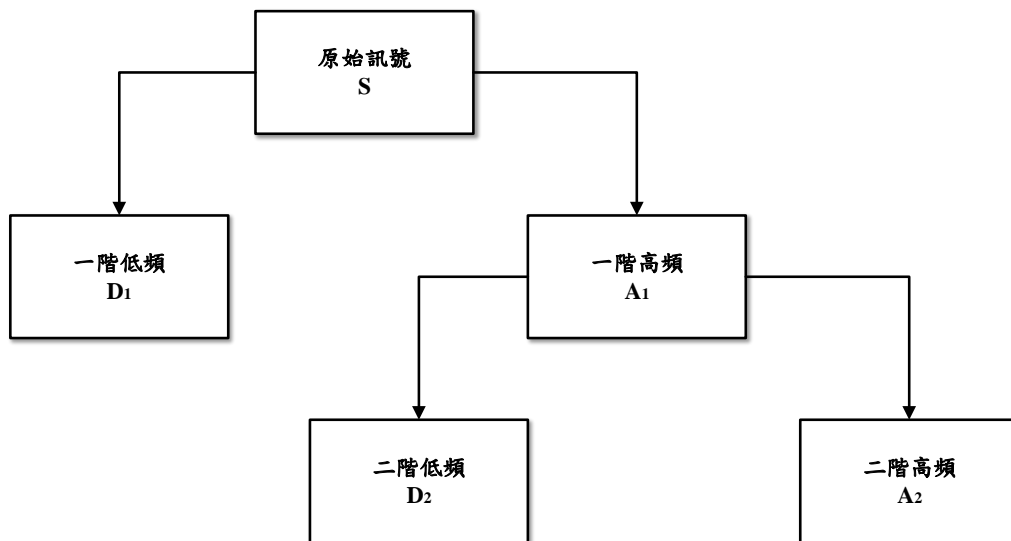


圖 3.1: 離散小波轉換階層架構



3.2.2 時間序列模型

3.2.2.1 時間序列預測 (Time Series Prediction Model)

將資料按照一定的時間間隔與發生順序紀錄而成的數列稱為時間序列 (time series)，時間序列預測透過序列本身所具有的時序性和自相關性，基於已知事件建構數學模型找出趨勢以確定未來事件 [39]。一個基本的時間序列預測模型方程式 (3.8) 所示 [40]：


$$\hat{y}(t+T) = f(y(t), y(t-T), \dots, y(t-mT)) \quad (3.8)$$

其中， T 為取樣的時間間隔； $\hat{y}(t+T)$ 為預測值； $y(t)$ 、 $y(t-T)$ 、 \dots 、 $y(t-mT)$ 為當下的實際觀測值與過去時刻的實際觀測值； m 值決定採用之前多少時刻的觀測值來進行預測。

方程式 (3.8) 表示：未來某一時刻的預測值僅依賴於前 m 個時刻的歷史觀測值。

3.2.2.2 平穩性與非平穩性 (Stationary and Non-Stationary)

時間序列通常存在非平穩性 (nonstationarity) 與時間波動 (time-varying volatility) 的特徵導致分析困難，若時間序列的統計特徵指標與時間無關，不會因為時間改變而變動，稱其具備平穩性或稱為恆定性。穩定性依據其形態分為強穩定性與弱穩定性，一般統計學中定義採用弱穩定性 (weakly stationary)：若時間序列 $\{Y_t\}$ 滿足方程式 (3.9)，則稱時間序列 $\{Y_t\}$ 是平穩的。



$$E(Y_t) = E(Y_{t-s}) = \mu \quad , \forall t, s \in \mathbb{N} \quad (3.9a)$$

$$E(Y_t - \mu)(Y_t - \mu) = E(Y_{t-s} - \mu)(Y_{t-s} - \mu) = \sigma_y^2 \quad , \forall t, s \in \mathbb{N} \quad (3.9b)$$

$$E(Y_t - \mu)(Y_{t-s} - \mu) = E(Y_{t-j} - \mu)(Y_{t-j-s} - \mu) = \gamma_s \quad , \forall t, s, j \in \mathbb{N} \quad (3.9c)$$

方程式 (3.9) 表示平穩時間序列的期望值 μ 、變異數 σ_y^2 和自相關係數 γ_r 均為常數，不因時間的變動而改變。

3.2.2.3 模型分類

一般將時間序列根據其是否滿足平穩性條件分為平穩性時間序列 (Stationary Time Series) 與非平穩時間序列 (Non-stationary Time Series)，並依此決定採用的時間序列預測模型。平穩性時間序列多採用自迴歸模型 (AR)、移動平均模型 (MA) 或自迴歸移動平均模型 (ARMA)；而非平穩時間序列需要透過差分運算使時間序列滿足平穩性，採用差分移動自迴歸模型 (ARIMA)。

自迴歸模型 (Autoregressive Model, AR Model) 使用時間序列自身作為迴歸變數，依賴於本身延遲的的滯後項和當前時間的干擾項對未來數值進行預測，其模型如方程式 (3.10) 所示，適用於平穩性時間序列。

$$\hat{y}_t = c + \sum_{i=1}^p \phi_i y_{t-i} + \epsilon_t \quad (3.10)$$

$$= c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \epsilon_t$$

其中， c 為常數項； ϕ_i ($i = 1, 2, \dots, p$) 為自相關係數； y_{t-i} ($i = 1, 2, \dots, p$) 為

時間序列中過去時刻的觀測值； ϵ_t 為當前時間的干擾項，代表無法由過去時刻資料所解釋的雜訊或白噪聲； p 為模型的自迴歸階數。一個 p 階的自迴歸模型記為 $AR(p)$ 。



移動平均模型 (Moving-Average Model, MA Model) 主要依賴於過去與當前時間的干擾項，對不同時期的雜訊或噪聲給予不同的權重來進行線性組合，其模型如方程式 (3.10) 所示，適用於平穩性時間序列。

$$\begin{aligned}\hat{y}_t &= c + \sum_{j=1}^q \theta_j \epsilon_{t-j} + \epsilon_t \\ &= c + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2} + \cdots + \theta_q \epsilon_{t-q} + \epsilon_t\end{aligned}\quad (3.11)$$

其中， μ 為時間序列的平均值； θ_j ($j = 1, 2, \dots, q$) 為移動平均係數； ϵ_{t-j} ($j = 1, 2, \dots, q$) 和 ϵ_t 分別為時間序列中過去時刻與當前時間的干擾項，代表雜訊或白噪聲； q 為模型的滑動平均階數。一個 q 階的移動平均模型記為 $MA(q)$ 。

自迴歸移動平均模型 (Autoregressive Moving-Average Model, ARMA Model) 採用了自迴歸模型與移動平均模型作為基礎，可以視為是兩個模型的線性組合，其模型如方程式 (3.12) 所示，適用於平穩性時間序列。

$$\hat{y}_t = \mu + \sum_{i=1}^p \phi_i y_{t-i} + \sum_{j=1}^q \theta_j \epsilon_{t-j} + \epsilon_t \quad (3.12)$$

其中，分別引入了方程式 (3.10) 和 (3.11) 所表示自迴歸模型與移動平均模型。一個包含了 p 階自迴歸項和 q 階的移動平均項的自迴歸移動平均模型記為 $ARMA(p, q)$ 。

整合自迴歸移動平均模型 (Autoregressive Integrated Moving-Average Model, ARIMA Model) 將非平穩時間序列透過方程式 (3.13) 的差分處理，使其具備平穩性之後再建立自迴歸移動平均模型，其模型如方程式 (3.14) 所示，適用於非平穩性時間序列。

$$y_t^{(d)} = y_t^{(d-1)} - y_{t-1}^{(d-1)} \quad (3.13)$$

$$\hat{y}_t^{(d)} = c + \sum_{i=1}^p \phi_i y_{t-i}^{(d)} + \sum_{j=1}^q \theta_j \epsilon_{t-j} + \epsilon_t \quad (3.14)$$

其中，分別引入了方程式 (3.10) 和 (3.11) 所表示自迴歸模型與移動平均模型，並使用差分處理後的時間序列進行預測； d 表示整合階數。一個經 d 次差分後方使具備平穩性，包含了 p 階自迴歸項和 q 階的移動平均項的整合自迴歸移動平均模型記為 $\text{ARIMA}(p, d, q)$ 。

3.2.2.4 平穩性檢驗 (Stationary Testing)

實務上在檢驗時間序列的平穩性時，會使用圖形檢驗法或單根檢驗法。圖形檢驗法透過觀察時間序列的走勢圖來判斷是否存在趨勢性與週期性，根據觀察者不同而有主觀性差異；單根檢驗法透過比較時間序列特徵根與單位圓位置關係判斷平穩性，實證分析中常用的單根檢定方法有：Dickey-Fuller 檢定 (DF 檢定)、Augmented Dickey-Fuller 檢定 (ADF 檢定)、Phillips-Perron 檢定 (PP 檢定)、Kwiatkowski, Phillips, Schmidt & Shin 檢定 (KPSS 檢定)、Elliott-Rothenberg-Stock Point-Optimal 檢定 (ERS Point-Optimal 檢定) 和 Ng-Perron 檢定 (NP 檢定) …等，以下針對本研究中所使用的 ADF 檢定與 KPSS 檢定進行說明。

Augmented Dickey-Fuller 檢定 (ADF 檢定) 延伸自 DF 檢定，修正了一般 DF 檢定只能用於檢驗一階時間序列相關穩定性的設定，因此可以用於檢測存在高階時間序列相關的穩定性。根據常數項或時間趨勢的有無，分為以下三種型態：

1. 無常數項以及時間趨勢

$$\hat{y}_t = \beta y_{t-1} + \sum_{j=1}^{p-1} \zeta_j \Delta y_{t-j} + \epsilon_t, \quad \epsilon_t \sim \mathcal{WN}(0, \sigma^2) \quad (3.15)$$

2. 含常數項但無時間趨勢

$$\hat{y}_t = \mu + \beta y_{t-1} + \sum_{j=1}^{p-1} \zeta_j \Delta y_{t-j} + \epsilon_t, \quad \epsilon_t \sim \mathcal{WN}(0, \sigma^2) \quad (3.16)$$

3. 含常數項以及時間趨勢

$$\hat{y}_t = \mu + \alpha t + \beta y_{t-1} + \sum_{j=1}^{p-1} \zeta_j \Delta y_{t-j} + \epsilon_t, \quad \epsilon_t \sim \mathcal{WN}(0, \sigma^2) \quad (3.17)$$

對於上述三個迴歸模型，其假設檢定為虛無假設 $H_0: \beta = 1$ ，對立假設 $H_1: \beta < 1$ ，若取 y_{t-1} 項 OLS 估計法下的 t 檢驗值作為 ADF 統計量值，如果 ADF 統計量小於臨界值，則說明其足夠小可以拒絕虛無假設，表示時間序列具備平穩性。

Kwiatkowski, Phillips, Schmidt & Shin 檢定 (KPSS 檢定) 有別於其他單根檢定法將虛無假設設為序列具有單根而傾向接受單根，改以變數滿足平穩作為其虛無假設，通常用來確認其他單根檢定法的檢定結果。假設迴歸模型如方程式

(3.18) 所示：

$$\hat{y}_t = \zeta t + u_t + \epsilon_t \quad (3.18)$$

其中 ζ_t 為一定向趨勢； u_t 為一隨機漫步，即 $u_t = u_{t-1} + u_t$ 且 u_t 為滿足獨立有共同分佈（independent and identically distributed） $i.i.d.(0, \sigma_u^2)$ 的隨機變數； ϵ_t 為一定態白噪音。假設檢定為虛無假設 $H_0: \sigma_u^2 = 0$ ，對立假設 $H_1: \sigma_u^2 > 1$ ，在此虛無假設為真的前提下可以推導出方程式 (3.19) 所示的 KPSS 檢定統計式。

$$LM = \frac{\sum_{t=1}^T S_t^2}{\hat{\sigma}_\epsilon^2} \quad (3.19)$$

其中 S_t 為殘差的累計總合； $\hat{\sigma}_\epsilon^2$ 為長期殘差變異數的估計值，在 KPSS 檢定中採用 Bartlett windows 準則來構建加權函數 $w(s, l) = 1 - s/(l + 1)$ 。KPSS 檢定法推導出上述檢定統計量的漸進分配並模擬出臨界值表，此檢定為右尾檢定，若檢定落於臨界值外則拒絕虛無假設，表示時間序列不具備平穩性，需進行差分處理。


3.2.2.5 模型識別 (Model Identification)

前述介紹的時間序列預測模型，最終皆能夠以整合自迴歸移動平均模型表示為 $ARIMA(p, d, q)$ 的形式，表 3.2 為整合自迴歸移動平均模型在選用特定階數時的特例與退化後的結果。

所謂的模型識別（model identification）即是指決定整合自迴歸移動平均模型 $ARIMA(p, d, q)$ 中階數的過程，此一階段將採用 Box-Jenkins 方法，透過自相關函數（Autocorrelation Function, ACF）與偏相關函數（Partial Autocorrelation

表 3.2: 整合自迴歸移動平均模型的特例

模型	說明
ARIMA(0, 0, 0)	白噪聲 (white noise)
ARIMA(0, 1, 0)	隨機漫步模型 (random walk)
ARIMA(p , 0, 0)	自迴歸模型 (AR Model)
ARIMA(0, 0, q)	移動平均模型 (MA Model)
ARIMA(p , 0, q)	自迴歸移動平均模型 (ARMA Model)



Function, PACF) 及其對應的相關圖形進行判斷。

自相關函數 (Autocorrelation Function, ACF) 反映了同一時間序列在不同時刻取值的相關程度，定義為第 k 個時間差的自協方差函數與標準差的商值，如方程式 (3.20) 所示。

$$\rho_k = \frac{\text{Cov}(y_t, y_{t+k})}{\sqrt{\text{Var}(y_t)\text{Var}(y_{t+k})}} = \frac{\gamma_k}{\sigma_y^2} \quad (3.20)$$

對於 $\text{AR}(p)$ 模型而言，其自相關函數會隨著階數 p 的增加而逐步衰減但不為零，呈現拖尾 (tail off) 的性質；而對於 $\text{MA}(q)$ 模型而言，其自相關函數會在階數 q 之後為零，呈現截尾 (cut off) 的性質。

偏相關函數 (Partial Autocorrelation Function, PACF) 定義為移除額外變數的影響後，時間序列 $\{y_t\}$ 與滯後 k 階時間序列 $\{y_{t-k}\}$ 的線性相關程度，通常以 ϕ_{kk} 來表示時間序列的偏相關函數，定義如方程式 (3.21) 所示。

$$\phi_{kk} = \frac{\text{Cov}(y_t, y_{t-k} | y_{t-1}, y_{t-2}, \dots, y_{t-k+1})}{\sigma_{y_t | y_{t-1}, y_{t-2}, \dots, y_{t-k+1}} \sigma_{y_{t-k} | y_{t-1}, y_{t-2}, \dots, y_{t-k+1}}} \quad (3.21)$$



對於 $AR(p)$ 模型而言，其偏相關函數會會在階數 q 之後為零，呈現截尾 (cut off) 的性質；而對於 $MA(q)$ 模型而言，其偏相關函數會隨著階數 p 的增加而逐步衰減但不為零，呈現拖尾 (tail off) 的性質。

由於平穩時間序列的自相關函數與偏相關函數分別具有不同特徵，在進行模型識別的過程中通常觀察其自相關函數圖形與偏相關函數圖形的特徵，比如是否截尾以及在何處截尾來決定模型的類型與具體階數，表 3.3 整合自迴歸移動平均模型的 ACF 與 PACF 圖形判斷準則。

表 3.3: 自相關函數與偏相關函數之特徵

模型	自相關函數 (ACF)	偏相關函數 (PACF)
AR (p)	指數衰減或振盪，具有拖尾性	在 p 階截尾，自 p 階後明顯消失
MA (q)	在 q 階截尾，自 q 階後明顯消失	指數衰減或振盪，具有拖尾性
ARMA (p, q)	指數衰減或振盪，具有拖尾性	指數衰減或振盪，具有拖尾性

透過 ACF 與 PCAF 圖形特徵進行初步階數選定之後，需要從眾多可選的模型中選出最適模型，此時需要使用方程式 (3.22) 所示的 AIC (Akaike's Information Criterion) 及 BIC (Bayesian Information Criterion) 作為評價模型優劣的指標。

$$AIC = -2 \ln L + 2k \quad (3.22)$$

$$BIC = -2 \ln L + k \ln n$$

其中， L 為模型似然函數 (Likelihood Function)，表示模型擬合指標； k 為滯後期數總和，作為自由度懲罰項避免模型發生過度擬合的情況。



3.2.3 支持向量迴歸

支持向量機 (Support Vector Machine, SVM) 是機器學習領域中的監督式學習方法，根據統計學習理論中的結構風險最小化原則提出，目前被廣泛應用於統計學上的分類 (classification) 與迴歸分析 (regression analysis) 中。

3.2.3.1 支持向量機 (Support Vector Machine, SVM)

給定一組數據 $\{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$ ，其中 $\mathbf{x}_i \in \mathbb{R}^d, y_i \in \{-1, 1\}$ ，空間中可以找到一劃分超平面 $\mathbf{w}^\top \mathbf{x}_i + b = 0$ 將其分開。對於 \mathbb{R}^d 空間中某點 $\mathbf{p} \in \mathbb{R}^d$ 到劃分超平面 $\mathbf{w}^\top \mathbf{x}_i + b = 0$ 的距離可以表示為方程式 (3.23) 所示。

$$d = \frac{1}{\|\mathbf{w}\|} \left| \mathbf{w}^\top \mathbf{p} + b \right| \quad (3.23)$$

為求解上述的線性分類問題，支持向量機定義間隔 (margin) 為距離劃分超平面最近樣本點到劃分超平面距離的兩倍，如方程式 (3.24) 所示，用以表示劃分超平面到不同標記之最近樣本點的距離總和。

$$\gamma := 2 \min_i \frac{1}{\|\mathbf{w}\|} \left| \mathbf{w}^\top \mathbf{x}_i + b \right| \quad (3.24)$$

經過簡化後，原有線性二分問題可以轉為限制條件為線性方程式的最佳化模型，如方程式 (3.25) 所示。

$$\begin{aligned} \max_{\mathbf{w}, b} \quad & \frac{1}{2} \mathbf{w}^\top \mathbf{w} \\ \text{s.t.} \quad & y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m \end{aligned} \quad (3.25)$$

圖 3.2 為二維平面上一個最優分類線的示意圖，其中藍色與褐色的點表示兩類樣本中的樣本點，直線 L_1 與 L_2 則分別代表兩類樣本中平行於分類線並與其距離最小的直線，兩者間距 d_{12} 可以表示為方程式 (3.26)，此間隔必須滿足 $2/\|w\|$ ，亦即保證分類間隔最大與使得 $\frac{1}{2}\|w\|^2$ 最小具有相同的意義；在高維空間中的分類線將變為一個分類面。

$$d_{12} = \min_{x_i, y_i=1} \frac{|w \cdot x_i + b|}{\|w\|} + \min_{x_j, y_j=-1} \frac{|w \cdot x_j + b|}{\|w\|} \quad (3.26)$$




圖 3.2: 二維平面上最優分類線
[二維平面上最優分類線]

對於帶有限制條件的最佳化問題，通常會構造其拉格朗日函數（Lagrange Function）進行求解，而引入拉格朗日函數後的規劃問題在極值處必須滿足庫恩塔克條件（Karush-Kuhn-Tucker Conditions, KKT Conditions）；除此之外，由於線性支持向量機滿足 Slater 條件，其對偶問題將等價於原問題。因此一個線性支

持向量機的對偶形式即找到一組合適的 α 滿足方程式 (3.27) 所示的最佳化問題。

$$\begin{aligned}
 \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j - \sum_{i=1}^m \alpha_i \\
 \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0 \\
 & \alpha_i \geq 0, \quad i = 1, 2, \dots, m
 \end{aligned} \tag{3.27}$$

此時若依據庫恩塔克條件 (Karush-Kuhn-Tucker Conditions, KKT Conditions) 進行求解，所得到的最優分類函數便如方程式 (3.28) 所示。

$$h(\mathbf{x}) = \text{sgn} \left(\sum_{i \in SV}^m \alpha_i y_i \mathbf{x}_i^\top \mathbf{x}_i + b \right) \tag{3.28}$$

定義支持向量 (Support Vector) 為對偶變數 $\alpha_i \geq 0$ 所對應的樣本，上式中的 SV 即代表所有支持向量所組成的集合。

3.2.3.2 核函數 (Kernal Functions)

在實際狀況中存在許多非線性可分的問題，因此不存在一個劃分超平面來將屬於不同標記的訓練樣本點進行分開，在支持向量機中透過核技巧 (Kernal Trick) 將特徵空間 \mathbb{R}^d 中非線性可分的樣本點映射至特徵空間 $\mathbb{R}^{\hat{d}}$ 中線性可分的樣本點，藉此來處理樣本非線性可分的狀況 [41]。將樣本點進行適當地映射之後，支持向量機的基本型和對偶型將分別轉變為方程式 (3.29) 和方程式 (3.30) 所示的最佳化問題。

$$\begin{aligned}
 \min_{\mathbf{w}, b} \quad & \frac{1}{2} \mathbf{w}^\top \mathbf{w} \\
 \text{s.t.} \quad & y_i (\mathbf{w}^\top \phi(\mathbf{x}_i) + b) \geq 1, \quad i = 1, 2, \dots, m
 \end{aligned} \tag{3.29}$$

$$\begin{aligned}
\min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j) - \sum_{i=1}^m \alpha_i \\
\text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0 \\
& \alpha_i \geq 0, \quad i = 1, 2, \dots, m
\end{aligned} \tag{3.30}$$



其中， $\phi(\mathbf{x}_i)$ 表示將樣本 \mathbf{x} 映射至特徵空間 $\mathbb{R}^{\hat{d}}$ 中的特徵向量。為使計算時的複雜度降低，核技巧透過塑造一個形如方程式 (3.31) 所示的核函數 (Kernel Function)，將特徵映射與內積運算壓縮為一個步驟。

$$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j) \tag{3.31}$$

其中，核函數必須滿足 Mercer 條件 (Mercer Condition)，亦即對於任意核函數 $\kappa(\mathbf{x}_i, \mathbf{x}_j)$ 所對應的矩陣 $\mathbf{K} := [\kappa(\mathbf{x}_i, \mathbf{x}_j)]_{m \times m}$ 必須為半正定的 [42]；除此之外，核函數也可以透過現有的核函數進行線性組合得到 [43]。表 3.4 為滿足 Mercer 條件的常見核函數。

在實際的機器學習過程中，核函數的選擇決定了計算的性能表現、模型的合適狀況以及預測的準確程度。核函數的選取主要依靠領域背景知識進行判斷，或者是採取交叉驗證法根據不同分析情況採用不同的核函數，目前在大多數的情況下將優先採用對於任意樣本都有較好學習能力的高斯徑向核函數。

3.2.3.3 支持向量迴歸 (Support Vector Regression, SVR)

在分類問題中，支持向量機尋找一個劃分超平面將樣本點一分為二；而在迴歸問題中，支持向量機尋找的則是能夠準確預測資料分佈的平面。

表 3.4: 滿足 Mercer 條件的常見核函數

名稱	形式	說明
線性核函數	$\mathbf{x}_i^\top \mathbf{x}_j$	容易實現並具高解釋性，但無法解決非線性可分問題
多項式核函數	$(\beta \mathbf{x}_i^\top \mathbf{x}_j + \theta)^n$	使用維度 n 來描述被映射空間複雜度，但參數太多，當維度太大時計算較不穩定
指數徑向核函數	$\exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ }{2\sigma^2}\right)$	沒有計算不穩定的問題，但計算速度較慢且容易過度擬合
高斯徑向核函數	$\exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ ^2}{2\sigma^2}\right)$	沒有計算不穩定的問題，但計算速度較慢且容易過度擬合
Sigmoid 核函數	$\tanh(\beta \mathbf{x}_i^\top \mathbf{x}_j + \theta)$	透過支持向量機實現了神經網路，結果與徑向核函數相似，但在某些參數下無效

假設訓練資料表示為 $\{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$ ，其中 \mathbf{x}_i 和 y_i 分別表示第 i 組資料的特徵和對應的迴歸值，且 $(\mathbf{x}_i, y_i) \in \mathbb{R}^d \times \mathbb{R}$ 。支持向量迴歸能夠容忍預測值 $h(\mathbf{x}_i)$ 與迴歸值 y_i 之間小於 ϵ 的偏差，並可以表示為方程式 (3.32) 所示的最佳化問題 [44]。

$$\begin{aligned}
 \min_{\omega, b} \quad & \frac{1}{2} \|\omega\|^2 \\
 \text{s.t.} \quad & \left| y_i - (\omega^\top \mathbf{x}_i + b) \right| \leq \epsilon, \quad i = 1, 2, \dots, m
 \end{aligned} \tag{3.32}$$

同樣地，在構造其拉格朗日函數並使用核函數將非線性可分的訓練資料進行映射後，支持向量迴歸可以形式化為方程式 (3.33) 所示的最佳化模型。

$$\min_{\omega, b} \quad \frac{1}{m} \sum_{i=1}^m \max\left(0, \left| y_i - (\omega^\top \phi(\mathbf{x}_i) + b) \right| - \epsilon\right) + \frac{\lambda}{2} \omega^\top \omega \tag{3.33}$$



3.2.4 模型評價方法

評價預測模型的好壞是計算預測結果與實際數據之間的誤差，常見的模型評價方法有以下幾種：

1. 均方根誤差 (Root Mean Squares Error, RMSE)：

$$E_{\text{RMSE}} = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2} \quad (3.34)$$

2. 平均絕對百分比誤差：

$$E_{\text{MAPE}} = \frac{1}{n} \sum_{t=1}^n \frac{|y_t - \hat{y}_t|}{|y_t|} \quad (3.35)$$

3. 平均絕對誤差 (Mean Absolute Error, MAE)：

$$E_{\text{MAE}} = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t| \quad (3.36)$$

4. 誤差平均值：

$$E_{\text{ME}} = \frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t) \quad (3.37)$$

3.3 收益模型分析

3.3.1 自由電力市場

早期世界各國的電力供應具有壟斷特性，直至二十世紀末歐美各國才紛紛重新組織電力產業，打破垂直整合的獨佔電力市場。自由電力市場會使得電力價格由市場機制決定，迫使電價下跌並推動電力設備升級，使用者也因此能受到更加

專業與透明的電力服務。




3.3.1.1 電力市場架構

國際上電力市場的發展歷程，主要可以將電力市場分成垂直壟斷、單一買方、批發競爭及零售競爭等四個主要架構，如圖 3.3 所示 [45]。在獨佔電力市場中，由一家獨佔電力機構將上下游所有的發電、輸電、配電與售電業務進行垂直整合；而在自由電力市場中，則將上下游所有的發電、輸電、配電與售電業務水平分割成能夠獨立運作的機構 [46]，這些機構可能為：


- **能源供應商 (Generation Company, GENCO)**：電力市場中的供給端，調度可支配的發電機組生產能源，並根據簽訂的售電合約或電力拍賣進行出售。可以藉由調度發電機組和選擇不同交易方式來調整自身收益狀況。
- **電力使用者 (Customer)**：電力市場中的需求端，獨佔電力市場中只能任由垂直整合綜合電業的電力公司制定電價進行交易，自由電力市場中可以自由選擇實惠的能源供應商簽約。通常根據規模可以分為大型用戶和個體用戶，大型用戶可以買賣電力，個體用戶僅能進行電力消費。
- **電力調度中心 (Independent System Operator, ISO)**：負責制定市場運作規則、發電調度控制、維持系統安全，並以絕對中立的方式提供使用者進行交易。

3.3.1.2 市場交易方式


綜合目前世界上已實施電業自由化之各國的電力買賣方式，依據交易地點的分散與否，可以將自由化電力市場的交易方式分成以下三種 [47]：




(a) 垂直壟斷



(b) 單一買方




(c) 批發競爭



(d) 零售競爭

圖 3.3: 常見電力市場架構

- 
- **雙邊合約模式 (Bilateral Contract Model)：**由供給端的能源供應商與需求端的電力使用者雙方直接簽訂交易合約，明定在特定時間內所願意交易的價格與數量，由電力調度所負責制定合約規範並在運作過程中檢驗供電品質。此模式下的供需雙方擁有較多選擇，但可能存在資訊不對等的狀況。
 - **電力池模式 (PoolCo Model)：**供給端的能源供應商與需求端的電力使用者必須向公正的電力交易場所 (Power Exchange, PX) 提出電力需求與競標價格，電力交易場所將依據雙方提供的資訊訂定市場結清價格 (Market-Clearing Price) 並告知買賣雙方進行交易。此模式下的供需雙方沒有太多選擇，但集中的協調、調度與定價流程有利於市場競爭。
 - **混合型模式 (Hybrid Model)：**結合了雙邊合約模式與電力池模式，供給端的能源供應商和需求端的電力使用者可以直接簽訂交易合約，也可以向電力交易所提出電力需求與競標價格，並從中選擇對自己較為有利的交易方式。此模式下既保留了一定的公平性，亦提供了相當程度的選擇。

其中，採用電力池模式或混合型模式的電力市場，皆需要透過電力交易場所 (Power Exchange, PX) 進行競標。目前根據電力調度中心與電力交易場所排程運作的時間，自由電力市場可以分成長期的期貨市場 (Future Market) 與短期的現貨市場 (Spot Market)。電力期貨市場可以進行跨幅提前數週、數月甚至數年的電力交易，以避免未來可能的價格波動；電力現貨市場包括了日前市場 (Day-Ahead Market)、日內市場 (Intra-Day Market) 與即時市場 (Real-Time Market)，其中又以日前市場最為常見。

在日前市場中，電力調度中心將於調度能源的前一天在電力交易場所公告預測的電力需求、電力最高價格、電力最低價格與競標重複一次所需時間…等相關交易資料，市場參與者必須在限定時間內提交可供調度的電力供給與競標價格，

最後自最低的價格開始進行調度直至滿足前一日預測的電力需求為止。



3.3.2 風機功率模型

風力發電的原理，是風推動風機轉動葉片後，透過齒輪箱提升轉速後經由發電機進行發電，其中涉及了一系列風能、機械能與電能的轉換過程。本研究中採用風力發電機組的標準功率曲線作為風機模型，用以將風速轉換為對應的風能。風速與功率的對應關係一般以分段函數表示如方程式 (3.38) 所示：

$$p_{wt}(v) = \begin{cases} p_r \cdot \frac{v^3 - v_{in}^3}{v_r^3 - v_{in}^3} & , v_{in} < v < v_r \\ p_r & , v_r \leq v < v_{out} \\ 0 & , \text{otherwise} \end{cases} \quad (3.38)$$

其中， $P_{wt}(v)$ 為風力發電機組在風速為 v 時所輸出的功率； p_r 為風力發電機組的額定功率，又稱為裝置容量 (capacity)，亦即風力發電機組所能輸出的最大功率； v_{in} 為風力發電機組的啟動風速，又稱為切入風速 (cut-in speed)，當風速大於啟動風速才開始運轉； v_{out} 為風力發電機組的停機風速，又稱為切出風速 (cut-out speed)，當風速大於停機風速時會因安全考量停止自動運轉； v_r 為風力發電機組的額定風速 (rated speed)。

方程式 (3.38) 表示：當風力發電機組的輸入風速大於啟動風速時，風力發電機組開始運轉，並根據不同的輸入風速產生相對應的電能，當風速達到額定風速時將以額定輸出功率運轉，當風速超過停機風速時，為保護葉片而停止輸出功率。



3.3.3 電動汽車電池

電動汽車係透過電池儲能的輸出推動馬達來行駛，為使電動汽車參與虛擬電廠進行電力市場交易，需要針對電動汽車電池原理進行了解。

3.3.3.1 電池設備概述

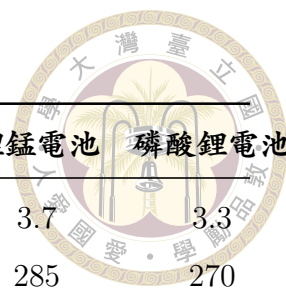
儲能電池設備透過電池內部的化學反應進行能量的釋放與儲存，一般儲能電池用於在緊急斷電狀況下及時供電或在用電尖峰時刻穩定電力系統，而電動汽車儲能電池為了推動馬達，還需要具備能夠長時間輸出一定大小電流。儲能電池設備主要由電池管理系統、交流／直流雙向轉換器與電池組所構成 [48]。

其中車用電池管理系統需要針對電池充電狀況 (State of Charge, SOC) 與電池健康狀況 (State of Health, SOH) 進行評估與建模；交流／直流雙向轉換器與充電座進行能量轉移，用於將電池輸出的直流電轉換為交流電或將交流充電座輸入的交流電轉換為直流電；電池組則由多個電池串聯組成，電動汽車主要採用二次電池作為動力來源，約略可以分為鉛酸電池、鎳鎘電池、鎳氫電池與鋰離子電池，表 3.5 為常見二次電池的特性比較 [49]，目前由於鋰電池相較其他電池而言具有較大的電流輸出與安全性，因此目前電動汽車廠商多針對鋰電池進行研究與推行車款。

3.3.3.2 電池充電方法

電池壽命除了會隨循環使用次數增加而降低之外，亦受到電池的充電與放電方式影響，採用適合的充電方法對於保護電池十分重要，常見的基本充電方法有定電壓充電法 (Constant Voltage Charge)、定電流充電法 (Constant Current Charge) 與脈衝充電法 (Pulsed Charge)。其中定電壓充電法為最普遍的充電方

表 3.5: 常見二次電池的特性比較



	鉛酸電池	鎳鎘電池	鎳氫電池	鋰錳電池	磷酸鋰電池
工作電壓 (V)	2	1.2	1.2	3.7	3.3
體積能量密度 (Wh/L)	100	150	250	285	270
重量能量密度 (Wh/Kg)	30	60	80	110	120
電池功率密度 (Wh/Kg)	300	150	800	400	2000
循環壽命 (次)	400	500	500	> 500	> 2000
能量效率 (%)	60%	75%	70%	90%	95%
安全性	佳	佳	佳	尚可	優
充電時間	長	短	中	中	短
記憶效應	無	大	小	無	無
環保問題	有	有	無	無	無

式，但存在無法確切估計充電時間且充電初期電流較大的問題；定電流充電法根據充電時間與電池容量設定電流值，但並未考慮初始電量狀態，充電效率不高且在高電壓時電池溫度會急遽上升；脈衝充電法透過週期性電流進行充電，能適當調整電流大小並有時間予以緩衝。

電池使用過程中，輸出容量佔其額定容量 E (Ah) 的百分比稱為放電深度 (Depth of Discharge, DoD)，定義如方程式 (3.39) 所示，其中 E (Ah) 為電池額定容量， E_r (Ah) 為電池剩餘電量。

$$\text{DoD (\%)} = \frac{E - E_r}{E} \times 100\% \quad (3.39)$$

不同的放電深度會影響二次電池的充電放電循環次數 [50]，因此一般會將電池壽命以其生命週期內的放電次數函數 $L(\text{DoD})$ 進行表示。



3.3.4 模型預測控制

模型預測控制 (Model Predictive Control, MPC)，又稱為移動時域控制 (Moving Horizon Control, MHC) 或後退時域控制 (Receding Horizon Control, RHC)，是近年來自動控制領域中被廣泛應用於工業上的一種反饋控制策略 [51]。透過模型預測控制可以在每一個時刻都根據當前的資訊求解有限時域內的最佳化問題，因此能夠更加精準地進行系統的控制，相較於傳統的控制方法更適合用於複雜系統中。

3.3.4.1 模型預測控制基本原理

模型預測控制的基本原理如圖 3.4 所示，左側為過去時刻的狀態，右側為未來時刻的狀態。模型預測控制法在當前時刻 k 時，根據過去時刻的狀態進行最佳化求解並預測未來輸出結果，在下一時刻時取前一次所得到的預測結果並捨棄其餘結果，並反覆進行此過程。




圖 3.4: 模型預測控制基本原理

一般可以將模型預測控制的實現步驟依次拆解為模型預測、滾動優化與反饋校正三個部分：



1. **模型預測**：此部分為模型預測控制的基礎，根據系統的當前狀態和預測模型，對未來行為與輸出進行預測，其中預測模型通常以狀態方程式的形式表示
2. **滾動優化**：模型預測控制在未來的有限時域內，透過某一性能指標的參考值進行未來控制決策的最佳化，其中下一時刻的只使用當前所得到控制變數來進行最佳化，並且反覆進行這個過程
3. **反饋校正**：由於採用有限時域進行預測，封閉的控制系統中同時存在外部干擾與內部模型不確定性，每一時刻都需要檢測當前系統實際的狀況，並根據實際數值與預測結果之間的誤差進行校正


3.3.4.2 模型預測控制數學模型

考慮線性離散時間系統的狀態空間模型如方程式 (3.40) 所示：

$$\begin{aligned}x(k+1) &= Ax(k) + B_u u(k) + B_d d(k) \\y_c(k) &= C_c x(k) \\y_b(k) &= C_b x(k)\end{aligned}\tag{3.40}$$

其中， k 為當前時刻， $x(k) \in \mathbb{R}^n$ 為狀態變數， $u(k) \in \mathbb{R}^n$ 為控制變數， $y_c(k) \in \mathbb{R}^n$ 和 $y_b(k) \in \mathbb{R}^n$ 為被控輸出變數與約束輸出變數， $d(k) \in \mathbb{R}^n$ 為可以被測量的外部干擾變數，而 A, B_u, B_d, C_c 和 C_b 為對應維度大小的系統矩陣。方程式 (3.40) 表示下一時刻的狀態變數 $x(k+1)$ 可以由當前時刻的狀態變數 $x(k)$ 和控制

變數 $u(k)$ 進行預測，且輸出變數為狀態變數與控制變數的函數。



為減少與消除靜態誤差，考慮方程式 (3.41) 所示的增量模型。

$$\begin{aligned}\Delta x(k+1) &= A\Delta x(k) + B_u\Delta u(k) + B_d\Delta d(k) \\ y_c(k) &= C_c\Delta x(k) + y_c(k-1) \\ y_b(k) &= C_b\Delta x(k) + y_b(k-1)\end{aligned}\tag{3.41}$$

其中， $\Delta x(k) = x(k) - x(k-1)$ 為狀態增量， $\Delta u(k) = u(k) - u(k-1)$ 為控制輸入增量， $\Delta d(k) = d(k) - d(k-1)$ 為被測量的外部干擾增量。

假設控制時域為 m ，預測時域為 p 且 $m \leq p$ ，則控制系統未來 p 步被控輸出和約束輸出的預測方程式可以表示為方程式 (3.42) 所示。

$$\begin{aligned}Y_{p,c}(k+1|k) &= S_{x,c}\Delta x(k) + I_c y_c(k) + S_{u,c}\Delta U(k) + S_{d,c}\Delta d(k) \\ Y_{p,b}(k+1|k) &= S_{x,b}\Delta x(k) + I_b y_b(k) + S_{u,b}\Delta U(k) + S_{d,b}\Delta d(k)\end{aligned}\tag{3.42}$$

其中， $S_{x,c}, I_c, S_{u,c}, S_{x,b}, I_b, S_{u,b}, S_{d,b}$ 為相應維度大小的系統預測矩陣。該控制系統的控制目標為使得被控輸入 y_c 滿足給定參考輸入 r ，同時系統的控制量、控制增量與輸出量須滿足方程式 (3.43) 所示的約束條件。

$$\begin{aligned}u_{\min}(k) &\leq u(k) \leq u_{\max}(k), \forall k \geq 0 \\ y_{\min}(k) &\leq y_b(k) \leq y_{\max}(k), \forall k \geq 0 \\ \Delta u_{\min}(k) &\leq \Delta u(k) \leq \Delta u_{\max}(k), \forall k \geq 0\end{aligned}\tag{3.43}$$

假設控制系統的全部狀態都可以被測量得到，在當前時刻 k 以測量值

$x(k), y_c(k), y_b(k)$ 作為預測系統未來動態預測的初始條件，根據預測控制的基本原理，可以將模型預測控制表示為方程式 (3.44) 所示的最佳化模型。



$$\begin{aligned}
 & \min_{\Delta U(k)} \quad J(x(k), \Delta U(k)) \\
 & \text{s.t.} \quad \Delta x(k+i+1|k) = A\Delta x(k+i|k) + B_u\Delta u(k+i) + B_d\Delta d(k+i) \\
 & \quad \Delta x(k|k) = \Delta x(k) \\
 & \quad y_c(k+i|k) = C_c\Delta x(k+i|k) + y_c(k+i-1|k), i \geq 1 \\
 & \quad y_c(k|k) = y_c(k) \\
 & \quad y_b(k+i|k) = C_b\Delta x(k+i|k) + y_b(k+i-1|k) \\
 & \quad y_b(k|k) = y_b(k) \\
 & \quad u_{\min}(k+i) \leq u(k+i) \leq u_{\max}(k+i) \\
 & \quad y_{\min}(k+i) \leq y_b(k+i) \leq y_{\max}(k+i) \\
 & \quad \Delta u_{\min}(k+i) \leq \Delta u(k+i) \leq \Delta u_{\max}(k+i)
 \end{aligned} \tag{3.44}$$

其中， $J(x(k), \Delta U(k)) = \|\Gamma_y(Y_{p,c}(k+1|k) - R(k+1))\|^2 + \|\Gamma_u\Delta U(k)\|^2$ 。在上述最佳化模型中， $R(k+1)$ 是給定的控制輸出參考向量，控制量增量向量 $\Delta U(k)$ 為約束最佳化問題的獨立變數，而 Γ_y 和 Γ_u 是對稱正定加權矩陣，定義如方程式 (3.45) 所示。

$$\begin{aligned}
 \Gamma_y &= \text{diag}\{\Gamma_{y,1}, \Gamma_{y,2}, \dots, \Gamma_{y,p}\}_{p \times p} \\
 \Gamma_u &= \text{diag}\{\Gamma_{u,1}, \Gamma_{u,2}, \dots, \Gamma_{u,m}\}_{m \times m}
 \end{aligned} \tag{3.45}$$

其中 $\Gamma_{y,i}$ 是在預測 i 時刻對被控輸出誤差的加權因子，其值越大表示期望對

應的預測控制輸出越接近給定的參考輸入；而 $\Gamma_{u,i}$ 是在預測 i 時刻對控制增量的加權因子，其值越大表示期望對應的控制動作變化越小。在進行控制器設計時，需要調節這兩個參數來滿足系統控制要求。



3.4 小結

本章扼要地描述了研究流程，並針對研究流程中的風力發電預測與收益模型分析部分所會使用到的方法與理論進行說明與介紹，包括了小波時頻轉換、時間序列預測、支持向量迴歸和模型預測控制…等。後續章節將根據本章所介紹的理論與方法進行模型建構以及案例分析，並詳述其內容與概念。



第四章 模型建構

本章為模型建構，在介紹完本文研究過程中所會使用到的理論與方法後，需要將這些理論與方法實際應用於模型中使用。這一章節將闡述各步驟中的建模流程以及收益分析中的等效模型與收益模型，並於下一章節進行案例分析。

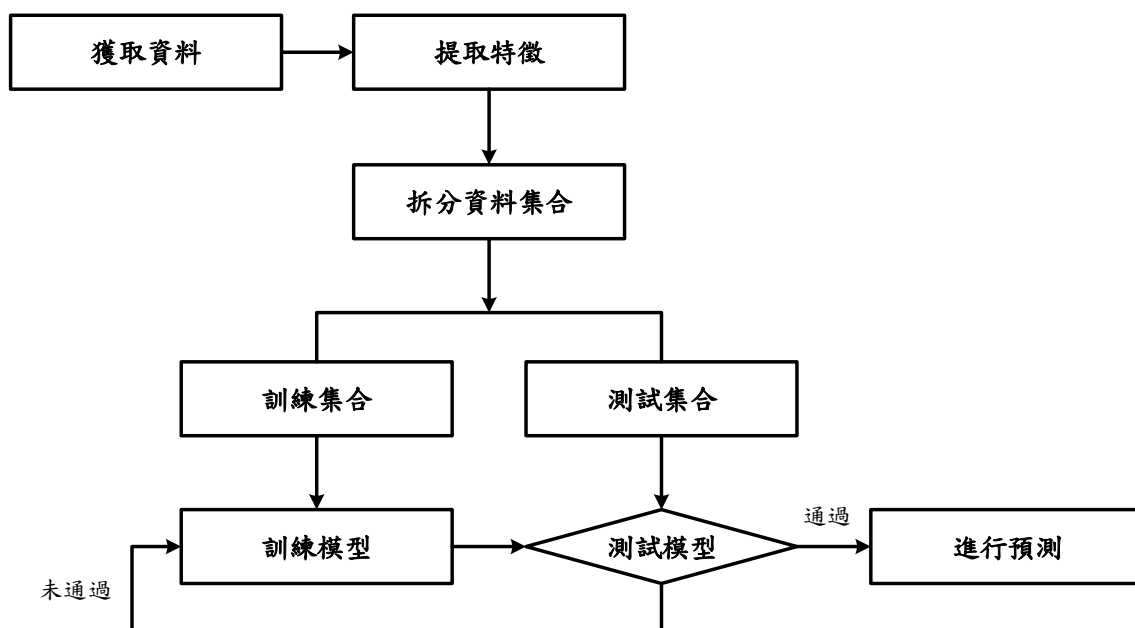
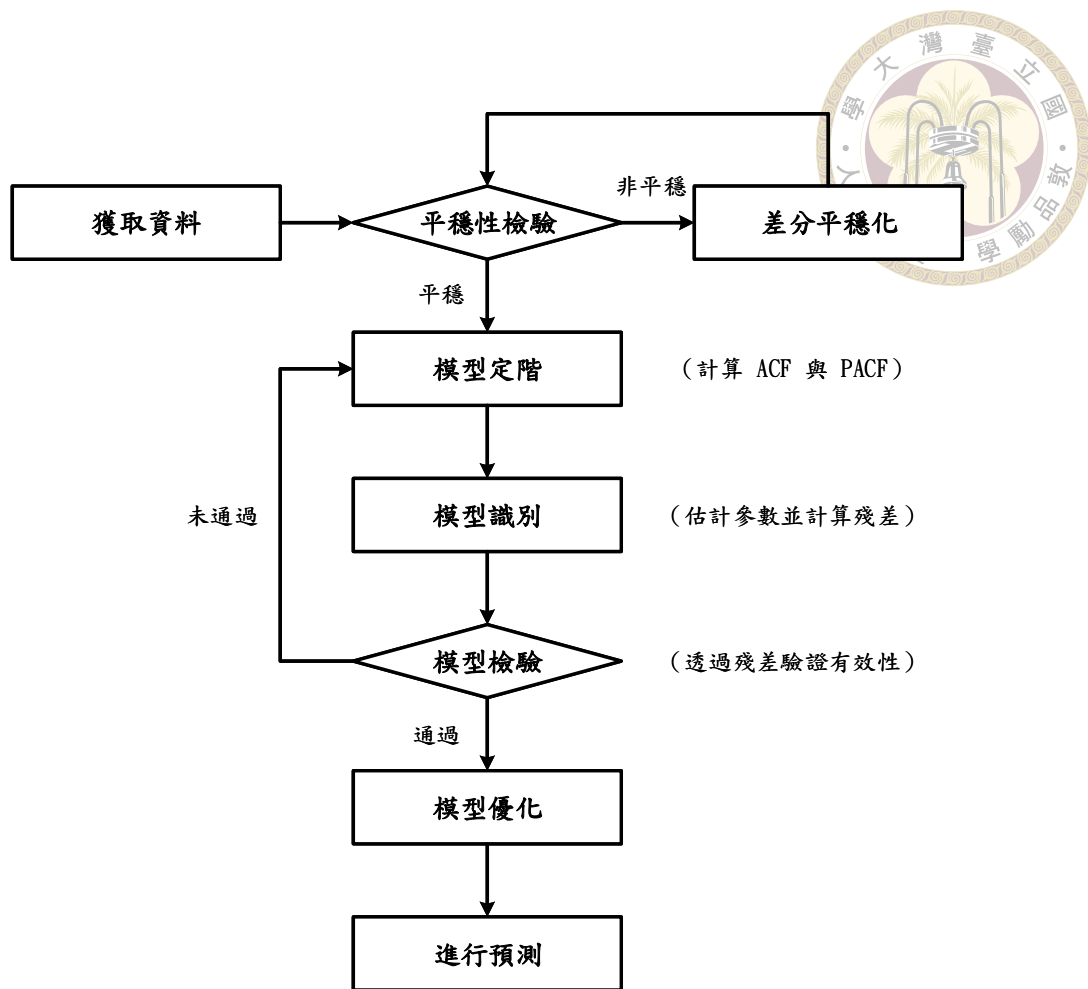
4.1 風力電場發電預測

4.1.1 時間序列預測建模流程

自迴歸移動平均模型 $ARIMA(p, d, q)$ 的建模流程如圖 4.1 所示。在取得時間序列資料後，需要先進行平穩性檢驗，若時間序列不具備平穩性則必須差分 d 次進行平穩化；接著繪製其 ACF 與 PACF 圖形並由其特徵初步決定其自迴歸項 p 與移動平均項 q 之值；初步階數選定之後透過 AIC 與 BIC 進行評價並選出最適模型以進行時間序列預測。

4.1.2 支持向量迴歸建模流程

支持向量迴歸模型建模流程如圖 4.2 所示，在取得時間序列資料後，將資料集合拆分為訓練集合與測試集合，選定核函數後進行模型訓練，使用測試集合進行評價並選出最適模型進行時間序列預測。





4.1.3 組合預測模型建模流程

常見的組合預測模型是將預測的結果進行線性組合，根據加權方式可以再分為採用等權的簡單平均組合以及變動權重組合，前者簡潔較易於計算但無法有效突出不同模型的優勢，後者則需要嘗試不同組合來尋找最佳的權重分配；小波分解則是將原始時間序列進行解構，根據分解後各分量的特性分別採取較佳的預測方法後再將結果進行組合，組合時不需進行權重的分配。本文將採用下述的兩種組合預測模型：

- 一般等權組合預測模型

$$\hat{y}(t) = \frac{1}{2}\hat{y}_{ARIMA}(t) + \frac{1}{2}\hat{y}_{SVR}(t) \quad (4.1)$$

- 小波分解組合預測模型

$$\hat{y}(t) = \hat{A}_2(t) + \hat{D}_1(t) + \hat{D}_2(t) \quad (4.2)$$

上述組合預測模型的建模流程分別如圖 4.3 和圖 4.4 所示。一般等權組合預測模型即為分別使用單一預測模型進行預測後，將預測結果使用同樣的權重進行線性組合；小波分解組合預測模型則需先將時間序列透過離散小波轉換分解為高頻部分（細節分量）與低頻部分（近似分量），並分別採用 ARIMA 模型預測與 SVR 模型預測，再將預測結果進行整合。




圖 4.3: 一般等權組合預測模型建模流程

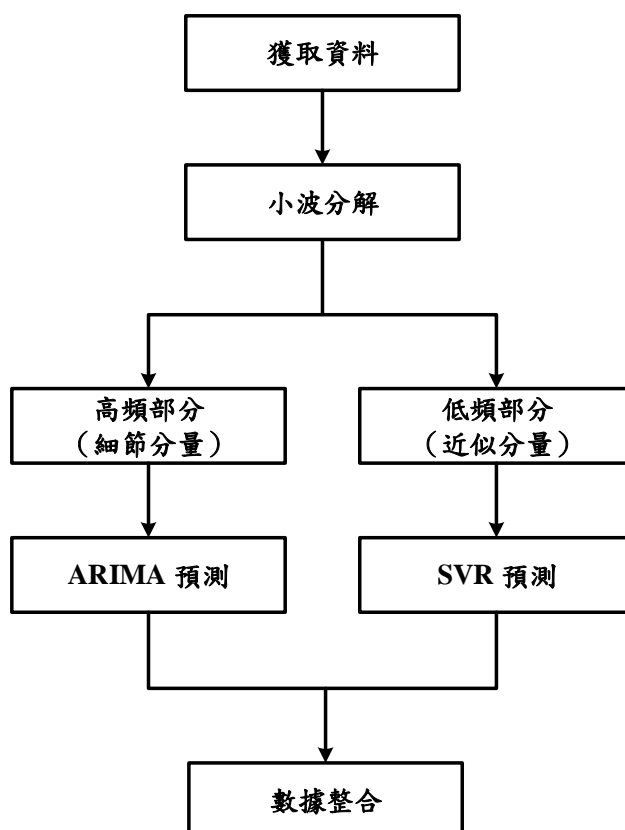


圖 4.4: 小波分解組合預測模型建模流程



4.2 虛擬電廠收益分析

4.2.1 虛擬電廠結構概述

本文虛擬電廠結構 (Virtual Power Plant, VPP) 如圖 4.5 所示，由風力電場 (Wind Farm, WF)、電動汽車 (Electric Vehicle, EV) 組成，分別透過發電與儲能來參與電力市場 (Electric Market, EM) 的日前市場調度。

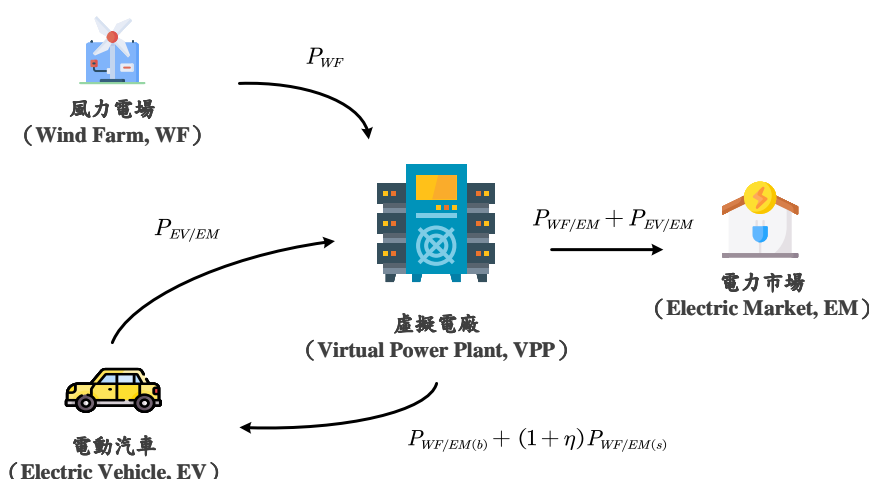


圖 4.5: 整合風力電場與電動汽車的虛擬電廠模型

在日前市場中，電力交易會在前一天完成並在當天公告交易資訊，最後在日前市場關閉後確定隔天的發電數量，發電業者需要簽約保證提供確定的發電數量，若提供的發電數量與確定的發電數量存在偏差，則需要進行賠償。亦即虛擬電廠必須在第 $(t - 1)$ 日提交價格資訊，並保證在第 t 日的每個時段提供一定的電力；在這樣的狀況下，風力電場需要在 $(t - 1)$ 日根據天氣資訊預估發電數量，並在給出第 t 日願意參與虛擬電廠的電動汽車後，決定最佳儲存容量來在日前市場中提出最有利的競標價格。

除此之外，由於參與儲能後會增加電動汽車電池的充電放電次數導致電池壽命減少，因此需要對電動汽車車主進行補償以促進其進行儲能來參與虛擬電廠的

動機。但參與虛擬電廠的電動汽車無法如同傳統儲能設備那般計算運轉成本，本文中並不採用直接給予金錢的補償支付，而是無償地向電動汽車提供充電，雖然減少了向電網供電的部分收入，但能夠將電力儲存於電動汽車來降低虛擬電廠的電力波動，整體而言卻能夠獲得更大收益。

4.2.2 風力電場等效模型

若已知特定風力機組 M 的額定功率曲線，則可以透過某一時刻 t 的風速資料 $v(t)$ 確定該時刻所對應的風力機組出力情況，如方程式 (4.3) 所示。

$$P_{wt,M}(t) = P_{wt,M}(v(t)) \quad (4.3)$$

假定一風力電場 (Wind Farm) 內設置有風力發電機組 M_1, M_2, \dots, M_k ，則在當天某一時刻 t 的預測發電總量可以表示如方程式 (4.4) 所示。

$$P_{WF}(t) = \sum_{i=1}^k P_{wt,M_i}(t) \quad (4.4)$$

在本文的模擬情況中，預測風速資料將以每一小時作為時間間隔，為了方便進行建模運算，最終將以向量形式表示在時間內該風力電場不同單位時刻的預測發電總量，用以參與電力市場作為日前市場的投標資訊，如方程式 (4.5) 所示。

$$\mathbf{P}_{WF} = [P_{WF}(1)P_{WF}(2)P_{WF}(3) \cdots P_{WF}(N)]^T \quad (4.5)$$



4.2.3 電動汽車等效模型

電動汽車透過儲存電能到電池中來參與虛擬電廠的電力市場交易，對於每一輛電動汽車 V 而言都有其對應的儲存容量，由於電動汽車電池壽命會受到放電深度（Depth of Discharge）影響，進而影響電動汽車駕駛的電力儲存偏好，因此可以透過放電深度 DoD 與電動汽車額定容量 E 來表示其儲存容量，如方程式 (4.6) 所示。

$$S_V(t) = \text{DoD} \times E \quad (4.6)$$

假定一電動汽車（Electric Vehicle）集合中設置有電動汽車 V_1, V_2, \dots, V_k ，則在當天某一時刻 t 的儲存容量總量可以表示如方程式 (4.7) 所示。

$$S_{EV}(t) = \sum_{i=1}^k S_{V_i}(t) \quad (4.7)$$

在本文的模擬情況中，為配合以每一小時作為時間間隔的預測風速資料進行建模運算，同樣將以向量形式表示在時間內所有電動汽車在不同單位時刻的儲存容量總量，如方程式 (4.8) 所示。

$$\mathbf{S}_{EV} = [S_{EV}(1)S_{EV}(2)S_{EV}(3) \cdots S_{EV}(N)]^T \quad (4.8)$$



4.2.4 電力市場收益模型

4.2.4.1 日前市場調度

根據前述的虛擬電廠架構，本文將根據風力電場的預測發電數量，調度電動汽車進行儲存能量來參與電力市場交易，並透過規劃求解虛擬電廠的最大收益，其最佳化模型可由方程式 (4.9) 表示。

$$\max \quad \sum_{t=1}^N p_e(t) [P_{WF/EM}(t) + P_{EV/EM}(t)] \quad (4.9a)$$

$$\text{s.t.} \quad P_{WF/EM}(t) + P_{WF/EV(b)}(t) + (1 + \eta)P_{WF/EV(s)}(t) = P_{WF}(t) \quad (4.9b)$$

$$\sum_{i=1}^{t-1} [P_{WF/EV(s)}(i) - P_{EV/EM}(i)] + P_{WF/EV(s)}(t) \leq P_{ST}(n) \quad (4.9c)$$

$$\sum_{i=1}^{t-1} [P_{WF/EV(s)}(i) - P_{EV/EM}(i)] - P_{EV/EM}(t) \geq 0 \quad (4.9d)$$

$$P_{WF/EV(b)}(t) \geq \sigma P_{ST}(n) \quad (4.9e)$$

$$0 \leq P_{ST}(n) + P_{WF/EV(b)}(t) \leq S_{EV}(t) \quad (4.9f)$$

$$P_{WF/EM}(t), P_{WF/EV(s)}(t), P_{WF/EV(b)}(t), P_{EV/EM}(t) \geq 0 \quad (4.9g)$$

其中， $p_e(t)$ 為虛擬電廠在電力交易市場中的販售電力價格； $P_{WF/EM}(t)$ 為風力電場輸送至電力交易市場中進行販售的電力數量； $P_{WF/EV(s)}(t)$ 為風力電場輸送至電動汽車電池中進行儲存的電力數量； $P_{WF/EV(b)}(t)$ 為風力電場輸送至電動汽車電池中作為補償的電力數量； $P_{EV/EM}(t)$ 為電動汽車輸送至電力交易市場中進行販售的電力數量； $P_{ST}(t)$ 為虛擬電廠需要的電力儲存容量； η 為電動汽車電池在充放電過程的能源轉換效率。

式 (4.9a) 為目標函數，為使電動汽車與風力電場參與虛擬電廠進行電力市場交易的收益最大，其中虛擬電廠販售電力收入可以表示為虛擬電廠販售給電網的電力價格 $p_e(t)$ 個別和虛擬電廠傳輸到電網的電力數量 $P_{WF/EM}(t)$ 與電動汽車傳輸到電網的電力數量 $P_{EV/EM}(t)$ 乘積的總和。

式 (4.9b) 為限制條件，表示風力電場在 t 時刻的預測發電數量 $P_{WF/EM}(t)$ 可以分配 $P_{WF/EM}(t)$ 輸送至電力交易市場中進行販售、 $P_{WF/EV(b)}(t)$ 輸送至電動汽車電池中作為補償、 $P_{WF/EV(s)}(t)$ 輸送至電動汽車電池中進行儲存，其中考慮了電動汽車電池在充放電過程中存在能源轉換耗損，每一單位的電力數量在充放電時會損失 η 單位的電力數量。

式 (4.9c) 為限制條件，表示在 t 時刻的電動汽車電池過去時刻所累積的（現在所擁有的）儲存電量 $\sum_{i=1}^{t-1} [P_{WF/EV(s)}(i) - P_{EV/EM}(i)]$ 與該時刻欲存入的儲存電量 $P_{WF/EV(s)}(t)$ 不得超過電動汽車的可用儲存容量 $P_{ST}(t)$ 。

式 (4.9d) 為限制條件，表示在 t 時刻的電動汽車電池能夠輸送至電力交易市場中進行販售的電力數量 $P_{EV/EM}(t)$ 不得超過電動汽車電池過去時刻所累積的（現在所擁有的）儲存電量 $\sum_{i=1}^{t-1} [P_{WF/EV(s)}(i) - P_{EV/EM}(i)]$ 。

式 (4.9e) 為限制條件，表示風力電場輸送至電動汽車電池中作為補償的電力數量 $P_{WF/EV(b)}(t)$ 需大於虛擬電廠需要的儲存容量 $P_{ST}(t)$ 的一定比例 σ 。

式 (4.9f) 為限制條件，表示在 t 時刻虛擬電廠需要的儲存容量 $P_{ST}(t)$ 與風力電場輸送至電動汽車電池中作為補償的電力數量 $P_{WF/EV(b)}(t)$ 必須小於所有電動汽車在該時刻的儲存容量總量 $S_{EV}(t)$ 。

式 (4.9g) 為非負限制式，表示在任一時刻的電力傳輸過程中，風力電場輸送至電力交易市場中進行販售的電力數量 $P_{WF/EM}(t)$ 、風力電場輸送至電動汽車電

池中進行儲存的電力數量 $P_{WF/EV(s)}(t)$ 、風力電場輸送至電動汽車電池中作為補償的電力數量 $P_{WF/EV(b)}(t)$ 和電動汽車輸送至電力交易市場中進行販售的電力數量 $P_{EV/EM}(t)$ 需滿足本文所提出之虛擬電廠架構的傳輸方向。



4.2.4.2 模型預測控制

模型預測控制需要在移動時域下進行規劃，因此在參與電力市場交易時需要在每一時刻更新其供電計劃。因此最佳化模型需要修正如方程式 (4.10) 所示。

$$\max \quad \sum_{t=1}^N p_e(t)[P_{WF/EM}(t) + P_{EV/EM}(t)] \quad (4.10a)$$

$$\text{s.t.} \quad P'_{WF/EM}(t) + P'_{WF/EV(b)}(t) + (1 + \eta)P'_{WF/EV(s)}(t) = P'_{WF}(t) \quad (4.10b)$$

$$\sum_{i=1}^{t-1} [P_{WF/EV(s)}(i) - P_{EV/EM}(i)] + P_{WF/EV(s)}(t) \leq P_{ST}(n) \quad (4.10c)$$

$$\sum_{i=1}^{t-1} [P_{WF/EV(s)}(i) - P_{EV/EM}(i)] - P_{EV/EM}(t) \geq 0 \quad (4.10d)$$

$$P_{WF/EV(b)}(t) \geq \sigma P_{ST}(n) \quad (4.10e)$$

$$0 \leq P_{ST}(n) + P_{WF/EV(b)}(t) \leq S_{EV}(t) \quad (4.10f)$$

$$P_{WF/EM}(t), P_{WF/EV(s)}(t), P_{WF/EV(b)}(t), P_{EV/EM}(t) \geq 0 \quad (4.10g)$$

其中， $p_e(t)$ 為虛擬電廠在電力交易市場中的販售電力價格； $P'_{WF/EM}(t)$ 為風力電場輸送至電力交易市場中進行販售的電力數量； $P'_{WF/EV(s)}(t)$ 為風力電場輸送至電動汽車電池中進行儲存的電力數量； $P'_{WF/EV(b)}(t)$ 為風力電場輸送至電動汽車電池中作為補償的電力數量； $P'_{EV/EM}(t)$ 為電動汽車輸送至電力交易市場中進行販售的電力數量； $P'_{ST}(t)$ 為虛擬電廠所需要的電力儲存容量； η 為電動汽車電池在充放電過程的能源轉換效率。

式 (4.10a) 為目標函數，為使電動汽車與風力電場參與虛擬電廠進行電力市場交易的收益最大，其中虛擬電廠販售電力收入可以表示為虛擬電廠販售給電網的電力價格 $p_e(t)$ 個別和虛擬電廠傳輸到電網的電力數量 $P_{WF/EM}(t)$ 與電動汽車傳輸到電網的電力數量 $P_{EV/EM}(t)$ 乘積的總和。

式 (4.10b) 為限制條件，表示風力電場在 t 時刻更新後的預測發電數量 $P'_{WF/EM}(t)$ 可以分配 $P'_{WF/EM}(t)$ 輸送至電力交易市場中進行販售、 $P'_{WF/EM(b)}(t)$ 輸送至電動汽車電池中作為補償、 $P'_{WF/EM(s)}(t)$ 輸送至電動汽車電池中進行儲存，其中考慮了電動汽車電池在充放電過程中存在能源轉換耗損，每一單位的電力數量在充放電時會損失 η 單位的電力數量。

式 (4.10c) 為限制條件，表示在 t 時刻更新後的電動汽車電池過去時刻所累積的（現在所擁有的）儲存電量 $\sum_{i=1}^{t-1} [P_{WF/EM(s)}(i) - P_{EV/EM}(i)]$ 與該時刻欲存入的儲存電量 $P_{WF/EM(s)}(t)$ 不得超過電動汽車的可用儲存容量 $P_{ST}(t)$ 。

式 (4.10d) 為限制條件，表示在 t 時刻的電動汽車電池能夠輸送至電力交易市場中進行販售的電力數量 $P_{EV/EM}(t)$ 不得超過電動汽車電池過去時刻所累積的（現在所擁有的）儲存電量 $\sum_{i=1}^{t-1} [P_{WF/EM(s)}(i) - P_{EV/EM}(i)]$ 。

式 (4.10e) 為限制條件，表示風力電場輸送至電動汽車電池中作為補償的電力數量 $P_{WF/EM(b)}(t)$ 需大於虛擬電廠需要的儲存容量 $P_{ST}(t)$ 的一定比例 σ 。

式 (4.10f) 為限制條件，表示在 t 時刻虛擬電廠需要的儲存容量 $P_{ST}(t)$ 與風力電場輸送至電動汽車電池中作為補償的電力數量 $P_{WF/EM(b)}(t)$ 必須小於所有電動汽車在該時刻的儲存容量總量 $S_{EV}(t)$ 。

式 (4.10g) 為非負限制式，表示在任一時刻的電力傳輸過程中，風力電場輸送至電力交易市場中進行販售的電力數量 $P_{WF/EM}(t)$ 、風力電場輸送至電動汽車



電池中進行儲存的電力數量 $P_{WF/EV(s)}(t)$ 、風力電場輸送至電動汽車電池中作為補償的電力數量 $P_{WF/EV(b)}(t)$ 和電動汽車輸送至電力交易市場中進行販售的電力數量 $P_{EV/EM}(t)$ 需滿足本文所提出之虛擬電廠架構的傳輸方向。

4.2.5 預測控制求解流程

模型預測控制求解流程如圖 4.6 所示，在取得當前時刻 t 的系統資訊後，求解預測時域內的最佳化收益結果，若未完成控制時域內之預測，求解控制變數 $U(t)$ 並使用下一時段之控制變數 $u(t+1)$ 進行系統調度，反覆進行以求得最佳收益。

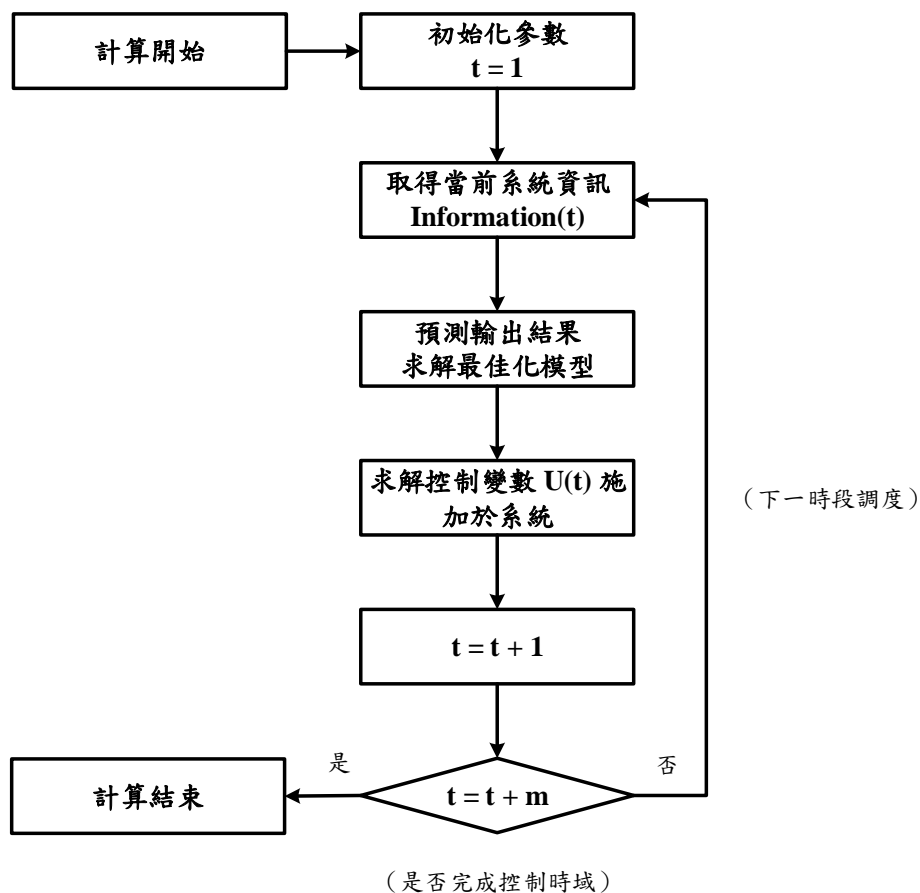


圖 4.6: 模型預測控制求解流程

4.3 小結



本章說明了短期風速預測中時間序列整合自迴歸移動平均模型、支持向量迴歸與使用離散小波進行分解的組合預測模型建模流程，以及收益分析中風力電場與電動汽車等效模型、虛擬電廠最佳化收益模型以及考慮了移動時域的模型預測控制求解流程。透過模型預測可以使得虛擬電廠在參與電力市場交易時，在有限時域中使用前一時刻的系統資訊進行模型規劃以求得最大利潤，在下一章節中將實際使用我國澎湖地區的風速資料進行發電預測並進行收益分析。





第五章 案例分析

本章為案例分析，第一部分進行風速預測分析，並計算不同預測模型的誤差結果來比較模型的預測能力，第二部分進行收益結果分析，並透過控制參數比較在不同情況下之收益結果。

5.1 模擬情境概述

本研究模擬與分析所使用的電腦，其硬體設備採用 Intel® Core™ i7 處理器，記憶體共 24 GB，運行 Microsoft Windows 10 作業系統。並使用 MathWorks 公司出品的商業數學軟體 MATrix LABoratory (MATLAB) 與以程式語言 Python 為基礎的數值分析與統計模型套件進行模擬與分析之程式開發。

關於歷史風速資料與模擬場址的選擇，考量我國澎湖、金門與馬祖地區由於孤立於臺灣本島的電力傳輸系統之外，較適合作為含風力發電與電動汽車的的虛擬電廠參與電力市場交易的模擬案例。本文使用東吉島 (DONGJIDAO) 測站 (北緯 $23^{\circ}15'32''$ ，東經 $119^{\circ}39'34''$) 於 2018 年的風速資料，並根據表 A.1 所示的我國風力發電場址資料，假設模型中的風力電場由八座 Enercon E40/600 Model 風力發電機組與四座 Enercon E44/900 Model 風力發電機組所構成。

收益分析部分的電力價格將採用因應不同用電狀況與發電情況所制定的時間

電價 (Time of Use Price, TOU)，這樣一來虛擬電廠在參與電力市場時，可以根據時間電價制定發電計畫，用以平衡波動並獲取較大收益，比如在離峰時段儲存電能至電動汽車，而在尖峰時段販售電力。但由於我國智慧電錶尚未完全普及，因此未能有效針對不同時段制定電價，而是以季節區分並制定大略峰值時段電價，本文將採用表 5.1 所示的臺灣電力公司非夏季兩段式電價進行收益計算 [52]。

表 5.1: 臺灣電力公司非夏季的兩段式電價 [52]

時間	電價 (元/度)
00:00 - 07:30	NT \$1.73
07:30 - 22:30	NT \$4.23
22:30 - 24:00	NT \$1.73

5.2 風速預測分析

5.2.1 歷史風速概述

此處採用東吉島 (DONGJIDAO) 測站於 2018 年間風速跨度較大的十二月份歷史風速資料進行風力電場短期發電預測示範計算，取該月份中前二十九日共 696 個小時的歷史風速作為觀測資料，預測最後二日共 48 小時的短期風速，並比較不同預測模型的誤差結果。在後續內容中，將選擇預測能力較佳的模型進行全年預測以作為收益分析中參與虛擬電廠的風力電場發電數量。

圖 5.1 為根據東吉島 (DONGJIDAO) 測站 2018 年十二月份的歷史風速資料所繪製的原始風速時間序列，顯示在該月份中所測得之歷史風速有較大幅度的變化，且初步判斷該時間序列具備趨勢性故為非平穩時間序列。

由於採用圖形檢驗法觀察時間序列平穩性可能根據觀察者不同而存在主觀性差異，本文採用 Augmented Dickey-Fuller 檢定進行單根檢驗，其平穩性檢驗結果




圖 5.1: 原始風速時間序列

如表 5.2 所示，由於 ADF 檢驗統計量並不同時小於在 99%、95% 與 90% 信賴區間下的 ADF 臨界檢驗值，因此原始風速資料時間序列為非平穩時間序列。

表 5.2: 原始風速時間序列 ADF 檢定結果

檢驗統計量	數值
Test Statistic	-3.217446
p-value	1.8997×10^{-2}
Critical Value (1%)	-3.439377
Critical Value (5%)	-2.865524
Critical Value (10%)	-2.568891

5.2.2 單一預測模型

5.2.2.1 ARIMA 模型

由於 ARIMA 模型的概念在於透過歷史資料的自相關性進行未來結果的預測，為使採用樣本時間序列所得到的擬合曲線在未來短期時間內延續既有型態，所採用的時間序列須具備平穩性。由前述內容已知原始風速時間序列為非平穩時間序列，因此需反覆計算時間序列中當前時刻與前一時刻的差值來取得其差分後的平穩時間序列。




圖 5.2: 差分風速時間序列

將原始風速時間序列進行一階差分後所得到的差分風速時間序列如圖 5.2 所示，由圖形可初步判斷該時間序列已具備平穩性。為避免觀察者不同而存在的主觀性差異，採用 Augmented Dickey-Fuller 檢定進行單根檢驗的平穩性檢驗結果如表 5.3 所示，其中 ADF 檢驗統計量已同時小於在 99%、95% 與 90% 信賴區間下的 ADF 臨界檢驗值，且 p-value 已十分接近零，因此該差分風速時間序列已為平穩時間序列。

表 5.3: 差分風速時間序列 ADF 檢定結果

檢驗統計量	數值
Test Statistic	-21.391265
p-value	5.817483×10^{-27}
Critical Value (1%)	-3.439206
Critical Value (5%)	-2.865448
Critical Value (10%)	-2.568851

圖 5.3 和圖 5.4 分別為差分時間序列的自相關係數函數 (Autocorrelation Function, ACF) 圖與非自相關係數函數 (Partial Autocorrelation Function, PACF) 圖，由圖形可知其自相關係數函數在延遲項 Lag 值為 2 時落入信賴區間中，其偏自相關係數函數在延遲項 Lag 值為 3 時落入信賴區間中，據此可認定其時間序列

具備平穩性並可大致識別其模型可採用 $ARIMA(2,1,3)$ 。





圖 5.3: 差分時間序列自相關係數函數 (ACF) 圖




圖 5.4: 差分時間序列偏自相關係數函數 (PACF) 圖

透過自相關係數函數圖與偏自相關係數函數圖進行模型定階可能存在主觀性差異，通常會使用 AIC (Akaike's Information Criterion) 及 BIC (Bayesian Information Criterion) 作為評價模型優劣的指標，採用窮舉法擬合所有模型並選出具有較小 AIC 值的最適模型。表 5.4 為使用開放式源代碼套件 pyramid 所提供的 `auto_arima()` 函數針對差分時間序列模型進行窮舉擬合所得到的結果，採用 AIC 值最小的 $ARIMA(2,1,0)$ 模型進行短期預測，預測結果如圖 5.5 所示。



表 5.4: 差分風速時間序列 $ARIMA(p, d, q)$ 適配檢驗

模型	AIC	BIC	Time
ARIMA(1, 1, 1)	1886.365	1904.808	0.229 s
ARIMA(1, 1, 2)	1886.528	1909.581	0.424 s
ARIMA(1, 1, 3)	1888.300	1915.964	0.404 s
ARIMA(1, 1, 4)	1890.242	1922.517	0.619 s
ARIMA(2, 1, 0)	1885.681	1904.124	0.087 s
ARIMA(2, 1, 1)	1887.588	1910.641	0.258 s
ARIMA(2, 1, 2)	1889.564	1917.228	0.165 s
ARIMA(2, 1, 3)	1890.281	1922.556	0.890 s
ARIMA(3, 1, 0)	1887.576	1910.630	0.110 s
ARIMA(3, 1, 1)	1889.572	1917.236	0.155 s
ARIMA(3, 1, 2)	1890.944	1923.219	0.955 s
ARIMA(4, 1, 0)	1889.565	1917.229	0.138 s
ARIMA(4, 1, 1)	1891.564	1923.839	0.184 s




圖 5.5: 單一 ARIMA 模型短期風速預測結果



5.2.2.2 SVR 模型

基於支持向量迴歸模型進行時間序列預測時，在將歷史風速資料進行標準化後，採用時間間隔為 1 單位的延遲，並選用高斯徑向核函數進行預測。使用開放式源代碼套件 sklearn 所提供的 SVR() 函數針對風速時間序列模型進行預測的結果如圖 5.6 所示。




圖 5.6: 單一 SVR 模型短期風速預測結果

5.2.3 組合預測模型

5.2.3.1 一般等權 ARIMA-SVR 組合模型

本文採用的一般等權 ARIMA-SVR 組合模型如方程式 (4.1) 所示，即使用相等權重將前述單一預測模型中 ARIMA 模型與 SVR 模型的預測結果進行線性組合。根據單一 ARIMA 模型與單一 SVR 模型預測結果進行相等權重線性組合的預測結果如圖 5.7 所示。




圖 5.7: 一般等權 ARIMA-SVR 組合模型短期風速預測結果

5.2.3.2 小波分解 ARIMA-SVR 組合模型

本文採用的小波分解 ARIMA-SVR 組合模型如方程式 (4.2) 所示，即將時間序列透過離散小波轉換分解為高頻部分（細節分量）與低頻部分（近似分量），並分別採用 ARIMA 模型預測與 SVR 模型預測，再將預測結果進行重構與整合。

針對時間序列採用較平滑且解析度較高的 Daubechies Wavelet 小波或 Symlet 小波進行分解較為合適。本文使用不同消失矩 N 的 Daubechies Wavelet 小波將原始風速時間序列進行不同層數的訊號分解後進行訊號重構所得到的誤差如表 5.5 所示，顯示採用 db4 小波進行 2 層的訊號分解能夠在訊號重構時產生較小的誤差。

表 5.5: 原始風速時間序列進行小波分解的重構誤差

分解層數	db ₃ 小波	db ₄ 小波	db ₅ 小波	db ₆ 小波
2 層分解	2.8931	1.1759	4.2143	3.2171
3 層分解	4.1932	2.1486	5.9631	4.7622
4 層分解	4.3194	3.0123	7.3174	5.4318

($\times 10^{-10}$)

在使用開放式源代碼套件 pywt 所提供的 wavedec() 函數，選擇 db4 小波對



原始風速時間序列進行 2 層小波分解與重構後，可以得到如圖 5.8 所示反映整體趨勢的近似分量 $A1$ ，以及如圖 5.9 和圖 5.10 所示反映細小波動的細節分量 $D2$ 和 $D1$ 。

採用 Augmented Dickey-Fuller 檢定對原始風速時間序列經小波分解後所得到的細節分量 $D2$ 和 $D1$ 進行單根檢驗，其平穩性檢驗結果分別如表 5.6 和表 5.7 所示，其中 ADF 檢驗統計量皆已同時小於在 99%、95% 與 90% 信賴區間下的 ADF 臨界檢驗值，且 p-value 已十分接近零，因此細節分量 $D2$ 和 $D1$ 皆為平穩時間序列。

表 5.6: 原始風速時間序列 $D2$ 細節分量 ADF 檢定結果

檢驗統計量	數值
Test Statistic	-13.40788
p-value	4.433267×10^{-25}
Critical Value (1%)	-3.439427
Critical Value (5%)	-2.865446
Critical Value (10%)	-2.568903

表 5.7: 原始風速時間序列 $D1$ 細節分量 ADF 檢定結果

檢驗統計量	數值
Test Statistic	-15.85389
p-value	9.380079×10^{-29}
Critical Value (1%)	-3.439427
Critical Value (5%)	-2.865446
Critical Value (10%)	-2.568903

如同前述步驟，針對細節分量 $D2$ 與 $D1$ 進行窮舉擬合後，分別選用 ARIMA(2, 0, 2) 與 ARIMA(2, 0, 1) 模型進行預測，並對近似分量 $A1$ 採用向量迴歸模型進行預測。最後將兩者預測結果進行整合可得到小波分解 ARIMA-SVR 組合模型的短期風速預測結果如圖 5.11 所示。




圖 5.8: 原始風速時間序列進行小波分解的近似分量 $A2$




圖 5.9: 原始風速時間序列進行小波分解的細節分量 $D2$




圖 5.10: 原始風速時間序列進行小波分解的細節分量 $D1$




圖 5.11: 小波分解 ARIMA-SVR 組合模型短期風速預測結果

5.2.4 模型誤差比較

為比較在短期風速預測中採用小波分解 ARIMA-SVR 組合模型是否相較傳統單一預測模型具有較好的效果，本文中使用同一段時間內的歷史風速資料，分別採用了單一 ARIMA 預測模型、單一 SVR 預測模型、一般等權 ARIMA-SVR 組合模型與小波分解 ARIMA-SVR 組合模型進行預測。

計算其平均絕對百分比誤差 (MAPE)、平均絕對誤差 (MAE) 與均方根誤差 (RMSE) 作為模型優劣的評價依據，結果如表 5.8 所示。

表 5.8: 風速預測模型評估結果

模型	MAPE	MAE	RMSE
單一 ARIMA 預測模型	5.3022%	0.7817	0.9692
單一 SVR 預測模型	5.4723%	0.8113	0.9869
一般等權 ARIMA-SVR 組合模型	5.2852%	0.7762	0.9651
小波分解 ARIMA-SVR 組合模型	5.1487%	0.7319	0.9517



5.3 收益結果分析

5.3.1 電動汽車有無影響

比較同一風力電場在有電動汽車作為儲能設備參與虛擬電廠與沒有電動汽車作為儲能設備參與虛擬電廠的收益，使用模型預測控制方法進行求解。

將每個月份中，將整合了電動汽車作為儲能設備的虛擬電廠收益記為 $\text{Profit}_{\text{with EV}}(t)$ ，而未整合電動汽車作為儲能設備的虛擬電廠收益記為 $\text{Profit}_{\text{without EV}}(t)$ ，則可以將整合了電動汽車作為儲能設備的虛擬電廠收益增長率表示如方程式 (5.1) 所示。

$$R_{\text{growth}} = \frac{\text{Profit}_{\text{with EV}}(t) - \text{Profit}_{\text{without EV}}(t)}{\text{Profit}_{\text{without EV}}(t)} \times 100\% \quad (5.1)$$

模擬結果顯示，整合了電動汽車作為儲能設備的虛擬電廠相較未整合電動汽車作為儲能設備的虛擬電廠，具有較高的收益。此外，當 σ 值較小時，由於儲能成本較低，而使虛擬電廠在電力市場電價較低時，儘可能儲存電力並於電力市場電價較高時進行販售。

5.3.2 電動汽車數量需求

5.4 小結



第六章 結論與建議

本章為結論與建議，結論部分將對本研究所獲得之結果進行歸納與總結，建議部分將綜合研究限制與未來研究進行說明。

6.1 結論

本研究以虛擬電廠 (Virtual Power Plant, VPP) 概念整合風力電場與電動汽車，以預測風速配合風機功率模型取得風力機組發電數量後，考慮電動汽車作為儲能設備並依據時間電價進行調度規劃來參與電力市場交易，並透過模型預測控制 (Model Predictive Control, MPC) 在有限時域下針對動態變化的虛擬電廠進行儲能調度來獲得最佳收益。主要工作包括：(1) 提出基於小波轉換分解風速時間序列訊號的 SVR-ARIMA 組合預測模型，據以預測短期風速 (2) 以虛擬電廠概念整合風力電場與電動汽車，建構其參與電力市場的日前調度模型 (3) 採用模型預測控制方法在有限時域下針對動態變化的虛擬電廠進行調度，評估納入電動汽車前後的收益狀況。

依據案例分析中採用東吉島 (DONGJIDAO) 測站歷史風速進行風速預測與收益分析之結果，有以下結論：

1. 使用小波轉換對風速時間序列進行訊號分解時，選用 db4 小波母函數能夠

在訊號重構後得到較小的誤差。

2. 採用 ARIMA 預測模型與 SVR 預測模型進行短期風速預測皆能獲得不錯的效果，範例計算顯示預測結果較真實結果約偏離 5.0% 至 6.0% 之間。
3. 透過小波分解時間序列訊號，對細節分量與近似分量分別採用 ARIMA 預測模型與 SVR 預測模型後，進行訊號重構的組合預測相較於單一預測模型能夠小幅度提升預測準確度。

6.2 建議



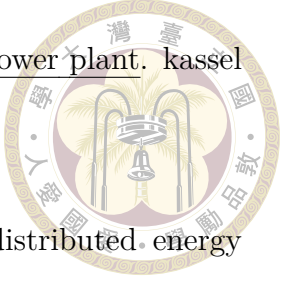
參考文獻

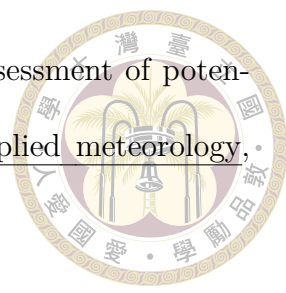
- [1] 中華民國行政院經濟部能源局. “能源統計資料”. <https://www.moeaboe.gov.tw/>. 存取時間：2020-05-01.
- [2] Enerdata. Electricity Domestic Consumption. <https://yearbook.enerdata.net/electricity/electricity-domestic-consumption-data.html>. 存取時間：2020-05-01.
- [3] 中華民國行政院經濟部能源局. “107 年全國電力資源供需報告”. https://www.moeaboe.gov.tw/ecw/populace/content/ContentDesc.aspx?menu_id=6985. 存取時間：2020-05-01.
- [4] International Energy Agency. “Data and Statistics: Electricity Generation by Source”. <https://www.iea.org/data-and-statistics/>. 存取時間：2020-05-01.
- [5] Mario Vignolo and Raul Zeballos. Transmission Networks or Distributed Generation? 2001.
- [6] 臺灣電力股份有限公司. “電網供電資訊：台電供電系統簡介”. <https://www.taipower.com.tw/tc/page.aspx?mid=211>. 存取時間：2020-05-01.
- [7] Matthew B Nissen. High performance development as distributed generation. IEEE Potentials, 28(6):25–31, 2009.
- [8] Sheryl Carter. Emissions from distributed generation. In California,

California Energy Commission Sitting Committee Workshop, 2000 [2014-6-28].


<http://www.distributed-generation.com/Library/Emissions.PDF>, 2000.

- 
- [9] Xiaogang He, Kairui Feng, Xiaoyuan Li, Amy B. Craft, Yoshihide Wada, Peter Burek, Eric F. Wood, and Justin Sheffield. Solar and wind energy enhances drought resilience and groundwater sustainability. Nature Communications, 10(1), November 2019.
- [10] World Wind Energy Association. “Global Wind Power Statistics” . <https://library.wwindea.org/>. 存取時間：2020-05-01.
- [11] Statista. “Cumulative installed solar PV capacity worldwide from 2000 to 2018”. <https://www.statista.com/statistics/280220/global-cumulative-installed-solar-pv-capacity/>. 存取時間：2020-05-01.
- [12] Karing Ohlenforst and Global Wind Energy Council. Global Wind Report 2018, 2019.
- [13] International Energy Agency (IEA). Renewables 2019: Analysis and forecasts to 2024. The Organisation for Economic Co-operation and Development (OECD), October 2019.
- [14] E Hertwich, J Aloisi de Larderel, A Arvesen, P Bayer, J Bergesen, E Bouman, T Gibon, G Heath, C Peña, P Purohit, et al. Green energy choices: The benefits, risks, and trade-offs of low-carbon technologies for electricity production. 2016.
- [15] NEF Bloomberg. Electric Vehicle Outlook 2019. Bloomberg New Energy Finance, 2019.

- 
- [16] Eko Adhi Setiawan. Concept and controllability of virtual power plant. kassel university press GmbH, 2007.
- [17] Peter Asmus. Microgrids, virtual power plants and our distributed energy future. The Electricity Journal, 23(10):72–82, December 2010.
- [18] D. Pudjianto, C. Ramsay, and G. Strbac. Virtual power plant and system integration of distributed energy resources. IET Renewable Power Generation, 1(1):10, 2007.
- [19] Danny Pudjianto, Goran Strbac, and David Boyer. Virtual power plant: managing synergies and conflicts between transmission system operator and distribution system operator control objectives. CIREN - Open Access Proceedings Journal, 2017(1):2049–2052, October 2017.
- [20] Martin Braun and Philipp Strauss. A review on aggregation approaches of controllable distributed energy units in electrical power systems. International Journal of Distributed Energy Resources, 4(4):297–319, 2008.
- [21] 呂奎宛. 虛擬電廠策略之整合性環境評估. Master’s thesis, 國立臺灣大學, January 2010.
- [22] 衛建宇. 虛擬電廠在自由化電力市場中的營運策略之研究. Master’s thesis, 國立中山大學, January 2014.
- [23] 林聖開. 含需量反應之虛擬電廠調度規劃. Master’s thesis, 國立中山大學, January 2015.
- [24] 鍾皓晨. 虛擬電廠之經濟效益分析與政策推介. 中興大學應用經濟學系所學位論文, pages 1–71, 2016.


- 
- [25] CG Justus, WR Hargraves, and Ali Yalcin. Nationwide assessment of potential output from wind-powered generators. Journal of applied meteorology, 15(7):673–678, 1976.
- [26] KA Nigim and Paul Parker. Heuristic and probabilistic wind power availability estimation procedures: Improved tools for technology and site selection. Renewable Energy, 32(4):638–648, 2007.
- [27] RK Panda, TK Sarkar, and AK Bhattacharya. Stochastic study of the wind-energy potential of India. Energy, 15(10):921–930, 1990.
- [28] Mekalathur B Hemanth Kumar, Saravanan Balasubramaniyan, Sanjeevikumar Padmanaban, and Jens Bo Holm-Nielsen. Wind Energy Potential Assessment by Weibull Parameter Estimation Using Multiverse Optimization Method: A Case Study of Tirumala Region in India. Energies, 12(11):2158, 2019.
- [29] 莊月璇. 台灣地區風速機率分佈之研究. 未出版之碩士論文. 國立中央大學土木工程研究所, 桃園市, 2001.
- [30] Alhassan Ali Teyabeen. Statistical analysis of wind speed data. In IREC2015 The Sixth International Renewable Energy Congress, pages 1–6. IEEE, 2015.
- [31] Robert B Cleveland, William S Cleveland, Jean E McRae, and Irma Terpenning. Stl: A seasonal-trend decomposition. Journal of official statistics, 6(1):3–73, 1990.
- [32] Grant Foster. Wavelets for period analysis of unevenly sampled time series. The Astronomical Journal, 112:1709, 1996.
- [33] Hui Liu, Hong-qi Tian, and Yan-fei Li. Comparison of two new arima-ann

and arima-kalman hybrid methods for wind speed prediction. Applied Energy, 98:415–424, 2012.



- [34] A. Kusiak, H. Zheng, and Z. Song. Short-term prediction of wind farm power: A data mining approach. IEEE Transactions on Energy Conversion, 24(1):125–136, March 2009.
- [35] Jianming Hu, Jianzhou Wang, and Guowei Zeng. A hybrid forecasting approach applied to wind speed time series. Renewable Energy, 60:185–194, 2013.
- [36] Hui Liu, Hong-qi Tian, Di-fu Pan, and Yan-fei Li. Forecasting models for wind speed using wavelet, wavelet packet, time series and artificial neural networks. Applied Energy, 107:191–208, 2013.
- [37] 丁怡汝. 時間序列於風速預測之分析與應用. 暨南大學資訊管理學系學位論文, (2015 年):1–72, 2015.
- [38] Stephane G Mallat. A theory for multiresolution signal decomposition: the wavelet representation. IEEE transactions on pattern analysis and machine intelligence, 11(7):674–693, 1989.
- [39] He Wang, Zhijian Hu, Mengyue Hu, and Ziyong Zhang. Short-term prediction of wind farm power based on PSO-SVM. In 2012 Asia-Pacific Power and Energy Engineering Conference. IEEE, March 2012.
- [40] George EP Box, Gwilym M Jenkins, Gregory C Reinsel, and Greta M Ljung. Time series analysis: forecasting and control. John Wiley & Sons, 2015.
- [41] Bernhard E Boser, Isabelle M Guyon, and Vladimir N Vapnik. A training

algorithm for optimal margin classifiers. In Proceedings of the fifth annual workshop on Computational learning theory, pages 144–152, 1992.



- [42] Nello Cristianini, John Shawe-Taylor, et al. An introduction to support vector machines and other kernel-based learning methods. Cambridge university press, 2000.
- [43] Gert RG Lanckriet, Nello Cristianini, Peter Bartlett, Laurent El Ghaoui, and Michael I Jordan. Learning the kernel matrix with semidefinite programming. Journal of Machine learning research, 5(Jan):27–72, 2004.
- [44] Harris Drucker, Christopher JC Burges, Linda Kaufman, Alex J Smola, and Vladimir Vapnik. Support vector regression machines. In Advances in neural information processing systems, pages 155–161, 1997.
- [45] 王京明, 郭婷瑋, 洪紹平, 許志義, and 孫承祥. 我國推動電業自由化之最適市場運作模式研究, 2015.
- [46] Mohammad Shahidehpour, Hatim Yamin, and Zuyi Li. Market operations in electric power systems: forecasting, scheduling, and risk management. John Wiley & Sons, 2003.
- [47] Tao Li and Mohammad Shahidehpour. Strategic bidding of transmission-constrained gencos with incomplete information. IEEE Transactions on power Systems, 20(1):437–447, 2005.
- [48] Hao Qian, Jianhui Zhang, Jih-Sheng Lai, and Wensong Yu. A high-efficiency grid-tie battery energy storage system. IEEE transactions on power electronics, 26(3):886–896, 2010.

- 
- [49] 許家興. 電動車電池類型與電池基礎介紹. 電動車與車輛電子研究報告, 財團法人車輛研究測試中心, 2009.
- [50] Jarno D Dogger, Bart Roossien, and Frans DJ Nieuwenhout. Characterization of li-ion batteries for intelligent management of distributed grid-connected storage. IEEE Transactions on Energy Conversion, 26(1):256–263, 2010.
- [51] Jacques Richalet, André Rault, JL Testud, and J Papon. Model predictive heuristic control. Automatica (Journal of IFAC), 14(5):413–428, 1978.
- [52] 臺灣電力股份有限公司. “臺灣電力股份有限公司電價表”. <https://www.taipower.com.tw/upload/238/2018070210412196443.pdf>. 存取時間：2019-12-11.





附錄 A — 再生能源場址

下述資料為臺灣電力公司所開放之我國再生能源場址資料，包含了我國再生能源各場址名稱、製造商、機組型號、單機運轉容量、安全調度日（與電力系統進行併聯後，發電時數長達 96 小時以上之初始調度日）、地址與座標。

表 A.1: 臺灣風力發電場址資料

場址名稱 (機組)	製造廠商 / 承包廠商	機組型號	運轉容量 (kW)	安全調度日	地址	座標
石門風力 (#1 - #6)	丹麥 Vestas (中興)	V47	660	2004/10/01	新北市石門區	25°17'34.6 N, 121°34'54.5 E
林口風力 (#4 - #6)	丹麥 Vestas (星能)	V80	2000	2010/09/08	新北市林口區	25°07'22.9 N, 121°18'31.7 E
蘆竹風力 (#1 - #8)	德國 ENERCON (中興)	E44	900	2014/10/31	桃園市蘆竹區	25°07'03.4 N, 121°16'35.7 E
觀園風力 (#1 - #20)	美國 GE (中興)	GE 1.5se	1500	2005/10/03	桃園市觀音區	25°04'15.9 N, 121°07'09.6 E
大潭風力 (#1 - #3)	美國 GE (中興)	GE 1.5se	1500	2005/03/18	桃園市觀音區	25°01'17.4 N, 121°02'45.2 E
大潭風力 (#4, #5, #8)	丹麥 Vestas (星能)	V80	2000	2011/02/07	桃園市觀音區	25°01'33.1 N, 121°02'23.8 E
大潭風力 (#6, #7)	德國 ENERCON (中興)	E70	2300	2010/12/15	桃園市觀音區	25°01'25.4 N, 121°02'24.4 E
香山風力 (#1 - #6)	西班牙 Gamesa (漢翔)	Gamesa	2000	2008/10/30	新竹市香山區	24°45'41.7 N, 120°54'16.9 E
中港風力 (#1 - #18)	荷蘭 Zephyros (樂士)	Zephyros Z-72	2000	2008/07/19	臺中市清水區	24°44'45.0 N, 120°53'57.1 E
中火風力 (#2 - #4)	荷蘭 Zephyros (樂士)	Zephyros Z-72	2000	2006/06/01	臺中市龍井區	24°18'15.8 N, 120°32'40.4 E
彰工風力 (#1 - #23)	丹麥 Vestas (星能)	V80	2000	2006/12/05	彰化縣伸港鄉	24°13'20.5 N, 120°28'39.8 E
彰工風力 (#24 - #31)	丹麥 Vestas (星能)	V80	2000	2010/11/16	彰化縣伸港鄉	24°09'29.1 N, 120°27'20.8 E
王功風力 (#1 - #10)	德國 ENERCON (中興)	E70	2300	2010/11/15	彰化縣芳苑鄉	24°09'27.9 N, 120°25'46.2 E
麥寮風力 (#1 - #15)	丹麥 Vestas (漢翔)	V80	2000	2008/12/16	雲林縣麥寮鄉	23°59'21.4 N, 120°19'55.6 E
麥寮風力 (#16 - #23)	丹麥 Vestas (星能)	V80	2000	2009/12/27	雲林縣麥寮鄉	23°49'12.0 N, 120°14'31.1 E
四湖風力 (#1 - #14)	丹麥 Vestas (星能)	V80	2000	2010/05/14	雲林縣四湖鄉	23°48'39.5 N, 120°15'42.5 E

場址名稱 (機組)	製造廠商 / 承包廠商	機組型號	運轉容量 (kW)	安全調度日	地址	座標
恆春風力 (#1 - #3)	美國 GE (中興)	GE 1.5se	1500	2005/01/13	屏東縣恆春鎮	21°57'18.4 N, 120°44'37.0 E
中屯風力 (#1 - #4)	德國 ENERCON (中興)	E-40/6.44	600	2001/09/13	澎湖縣白沙鄉	23°37'12.9 N, 119°36'34.6 E
中屯風力 (#5 - #8)	德國 ENERCON (中興)	E-40/6.44	600	2005/06/30	澎湖縣白沙鄉	23°36'57.0 N, 119°36'46.6 E
湖西風力 (#1 - #6)	德國 ENERCON (中興)	E44	900	2010/09/30	澎湖縣湖西鄉	23°35'09.1 N, 119°40'40.1 E
金沙風力 (#1 - #2)	丹麥 Vestas (星能)	V80	2000	2009/11/28	金門縣金沙鎮	24°29'20.2 N, 118°27'03.1 E



表 A.2: 臺灣太陽光電場址資料

場址名稱 (機組)	製造廠商 / 承包廠商	機組型號	運轉容量 (kW)	安全調度日	地址	座標
大潭光電	亞力電機	a2peak PEAK ON P230-60	235	2012/07/28	桃園市觀音區	25°01'52.3 N, 121°03'08.3 E
中大光電	均豪精密	AUO PM220P00	230	2012/08/07	桃園市中壢區	24°58'18.7 N, 121°12'02.0 E
中部儲運光電	淳宇科技	Apollo KAP-200-54	200	2011/03/14	臺中市后里區	24°19'22.5 N, 120°43'33.9 E
新伯公光電	淳宇科技	Sun Wall WD-A-CC-0872	85	2011/03/14	臺中市東勢區	24°13'16.9 N, 120°50'32.8 E
卓蘭光電	均豪精密	AUO PM220P00	230	2011/09/18	苗栗縣卓蘭鎮	24°19'11.3 N, 120°49'24.6 E
		SUNNER SOLAR SA-100	100			
台中電廠光電 (D, E 生水池)	台達電	Kyocera KD210GH-2P	210	2010/02/07	臺中市龍井區	24°12'29.2 N, 120°29'28.9 E
台中電廠光電 (B, C 生水池)	華城電機	Delsolar D6p240B3A	240	2013/11/23	臺中市龍井區	24°12'45.7 N, 120°29'26.9 E
龍井光電 (一期 I 標)	互立機電	TSM240A3-6100	240	2013/05/01	臺中市龍井區	24°12'22.0 N, 120°29'43.0 E
龍井光電 (一期 II 標)	華城電機	Delsolar D6p240B3A	240	2013/01/30	臺中市龍井區	24°12'32.6 N, 120°29'37.4 E
龍井光電 (二期)	亞力電機	GreenTriplex PM245P00	255	2014/08/06	臺中市龍井區	24°12'31.0 N, 120°29'43.6 E

場址名稱 (機組)	製造廠商 / 承包廠商	機組型號	運轉容量 (kW)	安全調度日	地址	座標
后里光電	大同公司	ASEC-245G6M	225	2012/10/06	臺中市后里區	24°19'05.3 N, 120°44'23.0 E
民雄光電	淳宇科技	SuN Wall WD-A-CC-0872	85	2011/03/14	嘉義縣民雄鄉	23°31'29.0 N, 120°27'22.9 E
永安鹽灘光電	華城電機	SUNTECH STP280-24/vd	280	2011/12/29	高雄市永安區	22°50'12.6 N, 120°12'23.5 E
興達電廠光電 (#3 - #6 生水池)	茂迪光電	Kyocera KD210GH-2P	210	2010/06/01	高雄市茄苳區	22°51'11.5 N, 120°12'03.2 E
興達電廠光電 (SCR 生水池)	均豪精密	AUO PM220P00	230	2010/09/18	高雄市茄苳區	22°51'11.5 N, 120°12'03.2 E
興達電廠光電 (#1 - #2 生水池)	華城電機	Delsolar D6p240B3A	240	2013/11/23	高雄市茄苳區	22°51'11.5 N, 120°12'03.2 E
路北光電	均豪精密	AUO PM220P00	230	2011/06/05	高雄市鼓山區	22°50'17.2 N, 120°14'52.6 E
核三廠光電	益鼎工程	SUNTECH STP280-24/vd	280	2012/07/20	屏東縣恆春鎮	21°57'21.1 N, 120°44'25.5 E
澎湖光電	均豪精密	AUO PM220P00	230	2011/05/10	澎湖縣湖西鄉	23°33'50.7 N, 119°39'32.5 E
金門光電	錦億實業	Apollo KAP-200	200	2010/03/14	金門縣金沙鎮	24°29'49.0 N, 118°24'09.8 E
七美光電 (一期)	廣運機械	KENMEC TKSA-23001	230	2012/03/08	澎湖縣七美鄉	23°12'15.3 N, 119°26'29.6 E
七美光電 (二期)	大同電機	GTEC295G6S6A	295	2018/01/22	澎湖縣七美鄉	23°12'15.3 N, 119°26'29.6 E



場址名稱 (機組)	製造廠商 / 承包廠商	機組型號	運轉容量 (kW)	安全調度日	地址	座標
龍潭光電	太創能源	MM60 SRT 300	300	2018/01/04	桃園市龍潭區	24°49'11.1 N, 121°11'37.8 E
竹工光電	太創能源	MM60 SRT 300	300	2018/02/09	新竹縣湖口鄉	24°53'35.7 N, 121°05'37.2 E
中科光電	太創能源	MM60 SRT 300	300	2018/03/30	台中市西屯區	24°12'04.1 N, 120°36'26.8 E
彭林光電	太創能源	MM60 SRT 300	300	2018/04/25	彰化縣埤頭鄉	23°55'44.4 N, 120°27'21.4 E
台南七股光電	華城電機	D6M-305-E3A	305	2018/09/12	台南市七股區	23°05'47.1 N, 120°08'09.0 E
高雄 ES 光電	立基電子	GTEC 295G6S6A	295	2018/05/22	高雄市三民區	22°38'46.6 N, 120°17'38.2 E
燕巢光電	立基電子	GTEC 295G6S6A	295	2018/05/31	高雄市燕巢區	22°46'28.8 N, 120°23'11.0 E
大潭光電	富台工程	D6M305H3A	305	2018/11/01	桃園市觀音區	25°01'21.9 N, 121°02'51.9 E
北儲光電	富台工程	D6M305H3A	305	2018/11/26	桃園市觀音區	25°01'35.0 N, 121°03'36.8 E
彰濱光電	中華電信	D6L295K3A	295	2019/02/18	彰化縣鹿港鎮	24°06'26.6 N, 120°23'46.0 E





附錄 B — 風力機組規格

本文研究的案例分析中，採用澎湖地區作為示範，根據表 A.1 的我國風力發電場址資料所示，該地區設有 Enercon E40/600 Model 與 Enercon E44/900 Model 風力機組，下述為此二風力機組之規格資料。

B.1 Enercon E40/600 Model

風機規格資料

- 額定功率 (Rated Power) : 600 kW
- 轉子直徑 (Rotor Diameter) : 40 m
- 掃掠面積 (Swept Area) : 1,257 m²
- 能量密度 (Power Density) : 2.1 m²/kW
- 葉片數量 (Number of Blades) : 3
- 葉輪最小額定轉速 (Minimum Rotor Speed) : 18 rd/min
- 葉輪最大額定轉速 (Maximum Rotor Speed) : 34.5 rd/min
- 額定風速 (Rated Wind Speed) : 13 m/s

- 切入風速 (Cut-in Wind Speed) : 2.5 m/s
- 切出風速 (Cut-off Wind Speed) : 25 m/s



風機功率曲線




圖 B.1: Enercon E40/600 Model 風機功率曲線

B.2 Enercon E44/900 Model

風機規格資料

- 額定功率 (Rated Power) : 900 kW
- 轉子直徑 (Rotor Diameter) : 44 m
- 掃掠面積 (Swept Area) : 1521 m²
- 葉片數量 (Number of Blades) : 3
- 葉輪最小額定轉速 (Minimum Rotor Speed) : 16 rd/min
- 葉輪最大額定轉速 (Maximum Rotor Speed) : 34.5 rd/min



- 額定風速 (Rated Wind Speed) : 17 m/s
- 切入風速 (Cut-in Wind Speed) : 3 m/s
- 切出風速 (Cut-off Wind Speed) : 25 m/s

風機功率曲線




圖 B.2: Enercon E44/900 Model 風機功率曲線